



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Impacto dos Fatores ESG no Desempenho Financeiro das Empresas: Uma abordagem multivariada

Denilson Cristovão Cardoso

Mestrado em Business Analytics

Orientador:

Doutor Ricardo João Lourenço Abreu, Associate Researcher,
ISCTE INSTITUTO UNIVERSITÁRIO DE LISBOA

JULHO, 2026



BUSINESS
SCHOOL

Departamento de Métodos Quantitativos para Gestão e
Economia

Impacto dos Fatores ESG no Desempenho Financeiro das Empresas: Uma abordagem multivariada

Denilson Cristovão Cardoso

Mestrado em Business Analytics

Orientador:

Doutor Ricardo João Lourenço Abreu, Associate Researcher,
ISCTE INSTITUTO UNIVERSITÁRIO DE LISBOA

JULHO, 2026

Dedicatória

A mim e à minha família, e a todos os que caminharam comigo nesta jornada.

Agradecimentos

Quero agradecer ao meu orientador, Professor Doutor Ricardo Abreu, por todo o apoio, dedicação e disponibilidade ao longo da elaboração desta tese.

Agradeço também ao Iscte, ao Professor Raul Laureano, aos meus professores do INDEG (pós-graduação em Analytics for Business) e a todos os professores que cruzaram o meu caminho ao longo destes dois anos.

À minha família Walter, Domingas, Lwena e Carina, por todo o apoio e por sempre acreditarem em mim; sem eles, nada disto teria sido possível.

Aos meus amigos, e a todos os que de alguma forma ajudaram, seja a ouvir os meus desabafos, seja a dar-me força.

Por último, e não menos importante, agradeço-me a mim próprio por nunca ter desistido e a Deus por permitir-me estar aqui hoje.

Resumo

A presente dissertação investiga o impacto das métricas Environmental, Social and Governance (ESG) no desempenho financeiro das empresas do índice S&P 500, no período 2019–2023, recorrendo a uma abordagem metodológica complementar que combina modelos econométricos de painel com efeitos fixos e modelação preditiva por Random Forest. Os resultados econométricos não evidenciam relações lineares estatisticamente significativas entre o ESG e as métricas de desempenho financeiro consideradas (Tobin's Q, ROA, ROE), mantendo-se essa conclusão em diversos testes de robustez. Em contraste, os modelos de Random Forest demonstram capacidade preditiva substancial (R^2 *out-of-sample* até 0,55 para o Tobin's Q), com a desagregação dos pilares ESG a melhorar consistentemente o desempenho. A análise de heterogeneidade setorial revela efeitos opostos e estatisticamente significativos em setores específicos, positivos em Industriais, negativos em Real Estate, evidência que estaria oculta numa leitura puramente agregada. A reduzida variação intraempresa dos *scores* ESG (26 a 52% da variação total) ajuda a contextualizar a ausência de significância estatística nos modelos com efeitos fixos. A combinação destas duas abordagens metodológicas constitui o principal contributo do trabalho, demonstrando que o impacto do ESG no desempenho financeiro é um fenómeno multifacetado e potencialmente não linear, mais adequadamente captado por estratégias analíticas complementares.

Palavras-chave: ESG; desempenho financeiro; dados em painel; Random Forest; heterogeneidade setorial.

Códigos JEL: G14 (Information and Market Efficiency); M14 (Corporate Culture; Social Responsibility).

Abstract

This dissertation investigates the impact of Environmental, Social and Governance (ESG) metrics on the financial performance of S&P 500 firms over the 2019–2023 period, using a complementary methodological approach that combines fixed-effects panel econometrics with Random Forest predictive modelling. Econometric results do not uncover statistically significant linear relationships between ESG and the financial performance metrics considered (Tobin's Q, ROA, ROE), with this conclusion holding across multiple robustness checks. In contrast, Random Forest models exhibit substantial predictive ability (out-of-sample R^2 up to 0.55 for Tobin's Q), with disaggregation of the ESG pillars consistently improving performance. Sectoral heterogeneity analysis reveals opposite and statistically significant effects in specific industries, positive in Industrials, negative in Real Estate, evidence that would remain hidden under a purely aggregated reading. The limited within-firm variation of ESG scores (26 to 52% of total variation) helps contextualise the lack of statistical significance in fixed-effects models. The combination of these two methodological approaches constitutes the main contribution of this work, showing that the impact of ESG on financial performance is a multifaceted, potentially non-linear phenomenon, best captured through complementary analytical strategies.

Keywords: ESG; financial performance; panel data; Random Forest; sectoral heterogeneity.

JEL Codes: G14; M14.

Índice

1	Introdução	1
1.1	Tema e sua Importância	1
1.2	Problema de Investigação	1
1.3	Objetivos e Contributos.....	2
1.4	Abordagem Metodológica.....	3
1.5	Estrutura da Tese	3
2	Revisão de Literatura.....	5
2.1	Introdução.....	5
2.2	Fundamentação Teórica.....	5
2.2.1	Conceitos ESG	5
2.2.2	Métricas de Desempenho Financeiro: ROA, ROE e Tobin's Q	6
2.3	Evidências empíricas sobre ESG e desempenho financeiro.....	6
2.3.1	Impacto Individual e Combinado das Dimensões ESG.....	7
2.3.2	Padrões de Práticas ESG Entre Empresas	8
2.3.3	Variações Setoriais nos Efeitos ESG	9
2.4	Lacunas na Literatura e Justificativa	10
2.5	Conclusão da Revisão da Literatura.....	11
3	Metodologia	13
3.1	Enquadramento Metodológico – CRISP-DM	13
3.2	Desenho da investigação.....	15
3.2.1	Hipóteses de Investigação	16
3.3	Amostra e Dados.....	16
3.4	Variáveis e Modelo Econométrico.....	18
3.4.1	Variáveis e Expectativas Teóricas	18
3.4.2	Procedimentos de Análise de Dados	22
3.5	Tratamento e Análise dos Dados.....	26

3.6	Modelação Preditiva com Random Forest	27
3.7	Estatísticas Descritivas e Análise Exploratória	29
3.7.1	Matriz de Correlação	30
4	Resultados e Discussão.....	33
4.1	Resultados das Regressões Lineares (Modelos Econométricos).....	33
4.1.1	Modelos OLS.....	33
4.1.2	Modelos de Paineis com Efeitos Fixos.....	33
4.2	Diagnósticos Econométricos	36
4.2.1	Multicolinearidade (VIF)	36
4.2.2	Testes de Diagnóstico dos Modelos em Painel.....	36
4.2.3	Testes de Robustez	37
4.3	Resultados da Modelação Preditiva (Random Forest).....	40
4.4	Integração dos Resultados Econométricos e Preditivos	45
4.5	Análise de Heterogeneidade Setorial	47
5	Conclusão	51
5.1	Síntese dos principais resultados	51
5.2	Contributos teóricos e metodológicos	52
5.3	Implicações práticas	53
5.4	Limitações	53
5.5	Sugestões para investigação futura.....	54
6	Referências Bibliográficas	55
7	Anexos.....	59

Índice de Tabelas

Tabela 1 – Tabela-síntese da literatura empírica	11
Tabela 2 – Descrição das variáveis utilizadas no estudo	19
Tabela 3 – Estatísticas descritivas das variáveis do estudo.....	29
Tabela 4 – Matriz de Correlação	31
Tabela 5 – Resultados das Regressões em Paineis com Efeitos Fixos (FE)	33
Tabela 6 – Resultados do Variance Inflation Factor (VIF)	36
Tabela 7 – Resultados dos Testes de Diagnóstico dos Modelos em Paineis	37
Tabela 8 – Resultados dos Modelos Alternativos (Testes de Robustez)	38
Tabela 9 – Desempenho Preditivo dos Modelos Random Forest (Out-of-Sample)	40
Tabela 10 – Permutation Importance (consolidada).....	43
Tabela 11 – Variação intraempresa (within-firm) dos scores ESG (2019-2023)	46
Tabela 12 – Heterogeneidade Setorial: Tobin's Q - ESG por Setor	48

Índice de Figuras

Figura 1 – Permutation Importance no Random Forest (Tobin's Q, modelo desagregado por pilares).....	42
Figura 2 – Permutation Importance no Random Forest (Tobin's Q, modelo agregado)	42
Figura 3 – Partial Dependence Plots: Tobin's Q vs Pilares ESG (modelo Random Forest desagregado)	43

1 Introdução

1.1 Tema e sua Importância

Nos últimos anos, os critérios ESG (Environmental, Social and Governance), passaram de preocupação marginal a variável central na avaliação das empresas. Investidores institucionais, reguladores e a sociedade em geral exercem hoje uma pressão crescente sobre as empresas para que divulguem e melhorem o seu desempenho nestas dimensões, influenciando decisões de investimento, estratégias corporativas e políticas públicas. Neste contexto, surge a questão de saber se o desempenho ESG se traduz efetivamente em melhores resultados financeiros ou em maior valorização de mercado.

Esta transformação levanta uma questão que, apesar de aparentemente simples, permanece sem resposta clara: melhorar no ESG traduz-se efetivamente em melhor desempenho financeiro? A evidência empírica existente não converge. Alguns estudos encontram uma relação positiva, outros resultados nulos ou negativos. Esta divergência não é apenas metodológica; reflete também a dificuldade real de separar o efeito do ESG de outros fatores que determinam o desempenho das empresas.

Adicionalmente, a maioria dos estudos continua a recorrer predominantemente a modelos econométricos lineares, sendo ainda limitada a evidência que combina abordagens explicativas e preditivas para analisar a relação entre ESG e desempenho financeiro. Neste contexto, permanece em aberto a questão de saber se os métodos tradicionalmente utilizados conseguem captar toda a informação relevante contida nas métricas ESG.

1.2 Problema de Investigação

É neste contexto de incerteza empírica que se enquadra a presente dissertação. A questão central que orienta a investigação é a seguinte:

- Em que medida o desempenho ESG influencia o desempenho financeiro das empresas?

Mais concretamente, o foco centra-se na variação intraempresa, procurando compreender se melhorias no desempenho ESG de uma empresa ao longo do

tempo se refletem na sua valorização de mercado ou na sua rentabilidade. Simultaneamente, procura-se avaliar se esta relação é semelhante quando analisada através do score ESG agregado ou dos seus pilares individuais: Environmental, Social e Governance.

Uma segunda dimensão da questão prende-se com a forma da relação. Caso o impacto do ESG não seja estritamente linear, podendo manifestar-se através de interações complexas ou efeitos não lineares, os modelos econométricos tradicionais poderão não ser capazes de captar integralmente essa informação.

1.3 Objetivos e Contributos

O objetivo central desta dissertação consiste em analisar a relação entre as métricas ESG e o desempenho financeiro das empresas através da combinação de duas abordagens metodológicas complementares: modelos econométricos em painel e técnicas de Machine Learning.

Especificamente, pretende-se:

(i) Avaliar a relação entre o desempenho ESG e métricas financeiras, nomeadamente o Tobin's Q, o Return on Assets (ROA) e o Return on Equity (ROE), através de modelos de regressão em painel com efeitos fixos;

(ii) Testar a robustez dos resultados através de especificações alternativas, incluindo variáveis defasadas e análise individual dos pilares ESG;

(iii) Avaliar a capacidade preditiva das variáveis ESG recorrendo ao algoritmo Random Forest, explorando a existência de relações não lineares;

(iv) Comparar os resultados obtidos pelas duas abordagens metodológicas, identificando os contributos e limitações de cada uma para a compreensão da relação entre ESG e desempenho financeiro.

O principal contributo desta investigação não reside em nenhuma das abordagens isoladamente, mas na sua combinação. Ao utilizar a econometria para análise explicativa e o Machine Learning para avaliação preditiva, procura-se obter uma compreensão mais abrangente do papel das métricas ESG no desempenho

financeiro das empresas.

1.4 Abordagem Metodológica

A amostra é composta por empresas pertencentes ao índice S&P 500 no período compreendido entre 2019 e 2023, utilizando dados obtidos através da plataforma Refinitiv Eikon. A escolha do S&P 500 justifica-se pela sua elevada representatividade do mercado acionista norte-americano, pela diversidade setorial das empresas que o compõem e pela ampla disponibilidade de informação ESG e financeira. O período analisado foi selecionado por corresponder a uma fase recente de crescente relevância das questões ESG, marcada pelo reforço das exigências de divulgação e pelo aumento da atenção dos investidores aos critérios de sustentabilidade.

Numa primeira fase, foram estimados modelos econométricos em painel com efeitos fixos de empresa e de ano. Esta especificação permite controlar a heterogeneidade não observada entre empresas e isolar a variação intraempresa ao longo do tempo. O desempenho ESG foi analisado tanto através do score agregado como dos três pilares ESG, utilizando como variáveis dependentes o Tobin's Q, o ROA e o ROE.

Numa segunda fase, é aplicado um modelo de Random Forest com o objetivo de avaliar a capacidade preditiva das variáveis ESG e identificar padrões que poderão não ser captados por especificações lineares tradicionais. Os resultados obtidos pelas duas abordagens são posteriormente comparados, permitindo analisar o que a convergência ou divergência entre os mesmos revela acerca da natureza da relação entre ESG e desempenho financeiro.

1.5 Estrutura da Tese

A presente dissertação encontra-se organizada em cinco capítulos.

- O Capítulo 2 apresenta a revisão da literatura, abordando os principais fundamentos teóricos associados às práticas ESG e sintetizando a evidência empírica existente sobre a relação entre sustentabilidade empresarial e desempenho financeiro.
- O Capítulo 3 descreve a metodologia de investigação, incluindo a caracterização da amostra, as variáveis utilizadas, os procedimentos de

tratamento dos dados e os modelos econométricos e preditivos implementados.

- O Capítulo 4 apresenta e discute os resultados obtidos, integrando a evidência proveniente dos modelos econométricos e da abordagem de Machine Learning.
- Por fim, o Capítulo 5 apresenta as principais conclusões da investigação, as suas implicações teóricas e práticas, as limitações do estudo e sugestões para futuras linhas de investigação.

2 Revisão de Literatura

2.1 Introdução

O interesse acadêmico pelo ESG cresceu em paralelo com a pressão que investidores, reguladores e sociedade civil exercem sobre as empresas para que tornem as suas práticas ambientais, sociais e de governação mensuráveis e comparáveis. No S&P 500, o universo desta dissertação, esse escrutínio é particularmente intenso: são empresas grandes, visíveis e sujeitas a exigências crescentes de transparência.

A questão central que a literatura tenta responder é se esse esforço de sustentabilidade se traduz em melhor desempenho financeiro. A resposta, até hoje, não é clara. Os estudos divergem não apenas nas conclusões, mas também nas metodologias utilizadas, nas amostras analisadas e nas formas de operacionalização das métricas ESG, o que torna difícil comparar resultados e extrair conclusões robustas.

Esta revisão organiza-se em torno de quatro eixos: os conceitos e métricas relevantes (2.2), a evidência empírica sobre o impacto do ESG (2.3), as lacunas que persistem na literatura (2.4) e uma síntese conclusiva (2.5).

2.2 Fundamentação Teórica

2.2.1 Conceitos ESG

O ESG surgiu como uma evolução mais estruturada da Responsabilidade Social Corporativa (CSR), respondendo à necessidade de critérios objetivos e comparáveis para avaliar a sustentabilidade empresarial. Zhang & Hao (2024), numa revisão sistemática recente, documentam a consolidação do ESG como referência dominante nesta avaliação, mas apontam também para uma fragilidade persistente: a falta de consenso sobre como definir e ponderar cada dimensão compromete a comparabilidade entre estudos e pode enviesar conclusões.

Shakil (2024) aprofunda esta crítica, mostrando que a agregação dos três pilares num único score esconde mais do que revela. Cada dimensão, ambiental, social e de governação, pode ter efeitos distintos sobre o desempenho financeiro, e as controvérsias ESG não são uniformes em termos de risco ou impacto reputacional. Tratar E, S e G como um bloco homogêneo é uma simplificação que

a literatura mais recente tem vindo progressivamente a questionar, e que esta dissertação procura evitar, optando por uma abordagem desagregada.

2.2.2 Métricas de Desempenho Financeiro: ROA, ROE e Tobin's Q

Os estudos sobre ESG e desempenho financeiro recorrem tipicamente a três indicadores: o Return on Assets (ROA), que mede a eficiência operacional; o Return on Equity (ROE), que avalia a rentabilidade para os acionistas; e o Tobin's Q, que capta a valorização de mercado em relação ao valor contabilístico dos ativos. Cada um mede uma coisa diferente, e os estudos que os usam em conjunto tendem a encontrar resultados distintos para cada métrica, o que por si só é informativo.

O Tobin's Q merece atenção especial neste contexto. Ao contrário do ROA e do ROE, que refletem resultados passados, o Tobin's Q incorpora as expectativas dos investidores sobre o desempenho futuro. Quando superior a um, sinaliza que o mercado valoriza a empresa acima do custo do seu capital instalado; quando inferior, sugere o oposto. Esta orientação para o futuro torna-o particularmente relevante para captar se os investidores incorporam fatores ESG nas suas expectativas de longo prazo, mesmo que esses fatores ainda não se reflitam nos resultados contabilísticos correntes.

Num estudo focado no mercado, Zhou et al. (2022) demonstram que o ESG impacta positivamente o valor de mercado das empresas através de um efeito mediador da eficiência operacional, sugerindo que as práticas sustentáveis criam valor de forma indireta, um mecanismo relevante para interpretar resultados em métricas como o Tobin's Q.

Para além destas três métricas, a literatura usa também o custo de capital e o Altman's Z-score. Mio et al. (2023) mostram que melhor desempenho ESG, sobretudo na dimensão de governação, reduz o custo do capital próprio. Cohen (2023) documenta que riscos ESG elevados, especialmente na dimensão social, aumentam a probabilidade de insolvência medida pelo Z-score. Giese et al. (2019) identificam três canais através dos quais o ESG afeta o desempenho: maior fluxo de caixa, menor risco idiossincrático e menor custo de capital, uma evidência de que os efeitos são multifacetados e se estendem no tempo.

2.3 Evidências empíricas sobre ESG e desempenho financeiro

A literatura empírica sobre ESG e desempenho financeiro apresenta resultados heterogéneos. Enquanto alguns estudos identificam uma associação positiva entre

sustentabilidade empresarial e criação de valor, outros encontram efeitos reduzidos, nulos ou mesmo negativos. Estas divergências têm sido frequentemente atribuídas a diferenças metodológicas, características das amostras analisadas, períodos temporais distintos e formas alternativas de operacionalização das métricas ESG. Consequentemente, a interpretação dos resultados exige cautela e uma análise crítica das condições em que cada estudo foi desenvolvido.

2.3.1 Impacto Individual e Combinado das Dimensões ESG

A relação positiva entre responsabilidade social e desempenho financeiro tem raízes empíricas longas. Orlitzky et al. (2003), numa meta-análise de 52 estudos, documentaram uma correlação positiva e robusta entre desempenho social e financeiro, estabelecendo uma das bases empíricas mais sólidas desta literatura.

A evidência mais recente aponta para que o impacto do ESG não seja uniforme entre dimensões nem independente do contexto. Vu et al. (2025), analisando ações de 23 mercados desenvolvidos, mostram que a relação entre os ratings ESG e os retornos esperados é fraca, sinal de que a informação ESG já se encontra largamente incorporada nos preços, mas que o desempenho do investimento ESG é condicionado pela atenção global à sustentabilidade, beneficiando sobretudo as empresas com governação mais forte em períodos de atenção crescente ao tema. Isto sugere que fatores externos, como a visibilidade mediática, moderam a relação ESG-performance de formas que os modelos tradicionais raramente captam. Alareeni & Hamdan (2020), analisando o S&P 500 entre 2009 e 2018, encontram uma relação positiva entre ESG e desempenho financeiro, com a dimensão social a apresentar o maior efeito individual.

Meehan e Corbet (2025) exploram um contexto diferente, a pandemia de COVID-19 e concluem que carteiras socialmente responsáveis (SRI) apresentaram menor volatilidade e recuperação mais rápida face a carteiras de setores controversos (SIN stocks). O ESG parece, neste caso, ter funcionado como amortecedor de risco em contexto de crise, o que é consistente com a ideia de que os seus benefícios são mais visíveis quando as condições de mercado se deterioram.

Esta resiliência em contexto de crise é igualmente documentada por Broadstock et al. (2021), que demonstram que empresas com scores ESG mais

elevados registraram melhor desempenho relativo durante a turbulência de mercado associada à COVID-19 na China, sugerindo que o ESG funciona como fator de proteção em períodos de stress financeiro.

A qualidade da divulgação também importa. Fatemi et al. (2018), com dados de empresas europeias, mostram que o efeito positivo do ESG sobre o valor de mercado é substancialmente maior quando a comunicação das práticas é clara e estruturada, e pode mesmo inverter-se quando a divulgação é deficiente. Isto levanta uma questão metodológica relevante: estudos que não controlam para a qualidade do disclosure podem estar a medir ruído tanto quanto sinal.

A dimensão de Governança emerge repetidamente como a mais robusta. Kim e Li (2021) documentam que estruturas de governança sólidas reduzem o custo de capital e melhoram o acesso a financiamento em empresas norte-americanas. Mio et al. (2023) chegam à mesma conclusão no setor de utilities europeu. Nguyen et al. (2022), usando modelos 2SLS para mitigar endogeneidade, encontram efeitos positivos do ESG sobre ROA, ROE e Tobin's Q no S&P 500, com os efeitos contabilísticos mais visíveis no longo prazo e o Tobin's Q mais sensível no curto prazo. Apesar destes resultados, permanece em aberto a possibilidade de a relação entre ESG e desempenho financeiro não ser estritamente linear. Alguns autores sugerem que os benefícios associados às práticas ESG podem depender da existência de determinados limiares, interações entre variáveis ou características específicas das empresas, o que poderá explicar parte das inconsistências observadas na literatura empírica. Eccles et al. (2014) corroboram esta evidência num estudo longitudinal de 18 anos, mostrando que empresas com políticas de sustentabilidade voluntárias apresentam desempenho financeiro e bolsista significativamente superior ao de empresas sem essas políticas, sugerindo que os benefícios do ESG se acumulam no longo prazo.

2.3.2 Padrões de Práticas ESG Entre Empresas

A interpretação dos resultados empíricos é ainda dificultada pela qualidade desigual das práticas de reporte ESG e pela ausência de padrões totalmente uniformizados entre empresas e mercados. Consequentemente, diferenças nos scores ESG podem refletir não apenas diferenças reais de sustentabilidade, mas também diferenças na qualidade da divulgação da informação.

A adoção de práticas ESG varia muito entre empresas em termos de

maturidade, consistência e ligação à estratégia. Hluszko et al. (2024) analisaram relatórios de sustentabilidade de empresas industriais na América Latina e constataram que menos de metade dos temas materiais estavam explicitamente ligados aos pilares ESG, com metas pouco claras, prazos indefinidos e fraca ligação entre objetivos e ações concretas. O ESG está a ser adotado, mas frequentemente de forma superficial.

Esta superficialidade tem um nome: greenwashing. Agbakwuru et al. (2024) e Lim (2024) documentam como a falta de padronização nos relatórios e a ausência de métricas uniformizadas facilitam a adoção simbólica de práticas ESG sem transformação real das operações. A consequência para a investigação empírica é relevante: se os scores ESG captam comprometimento formal mais do que mudança real, a relação com o desempenho financeiro será necessariamente fraca.

Vilas et al. (2022) acrescentam uma crítica às próprias classificações ESG. Mesmo em índices reconhecidos como sustentáveis, como o FTSE4Good, critérios financeiros como o tamanho de mercado prevalecem sobre métricas genuinamente ESG, o que levanta dúvidas sobre se esses índices medem o que dizem medir.

2.3.3 Variações Setoriais nos Efeitos ESG

A relação entre ESG e desempenho financeiro não é a mesma em todos os setores e ignorar esta heterogeneidade produz conclusões enganosas. Jucá et al. (2024), com dados de 625 empresas em 29 países, mostram que controvérsias ESG reduzem significativamente o ROE, sobretudo em setores ambientalmente sensíveis e em países desenvolvidos. Hussain et al. (2024) encontram efeitos positivos da divulgação ESG em empresas sauditas não manufatureiras, mas mais fracos nos setores industriais.

Alfalih (2023) acrescenta uma dimensão temporal: os efeitos positivos do ESG são mais fortes em períodos de crescimento económico, e a sensibilidade a cada pilar varia por setor, manufatura responde mais às dimensões social e de governação, serviços mais à ambiental. Parashar et al. (2024), usando K-means++ em empresas de energia limpa, mostram que mesmo dentro de um setor a relação ESG-ROE varia significativamente entre grupos de empresas com perfis distintos.

De Roos (2023) sintetiza bem esta heterogeneidade: no Europe Stoxx 600, o ESG está positivamente associado ao ROE, mas negativamente ao Tobin's Q e os

efeitos diferem entre setores, com comunicação e utilities a beneficiar mais e saúde e materiais a mostrar resultados ambíguos. Estes resultados sugerem que análises agregadas podem ocultar diferenças economicamente relevantes entre setores e empresas.

2.4 Lacunas na Literatura e Justificativa

A literatura sobre ESG e desempenho financeiro é extensa, mas tem três fragilidades recorrentes que os próprios estudos identificam.

A primeira é a agregação excessiva. Zhang & Hao (2024) e Shakil (2024) criticam a tendência para usar o score ESG composto sem distinguir os efeitos de cada pilar. Zhou et al. (2021) ilustram o problema concretamente: num estudo sobre risco de colapso do preço das ações, apenas a dimensão de governação apresenta um efeito consistente, ambiental e social são instáveis. Agregar os três dilui esta informação.

A segunda é a homogeneidade metodológica. A maioria dos estudos usa modelos lineares e ignora relações não lineares ou interações entre variáveis. De Lucia et al. (2020) e Kaminskyi & Nehrey (2023) defendem explicitamente o uso de Machine Learning para superar esta limitação.

A terceira é a falta de segmentação setorial e padronização. Gillan et al. (2021) e Brooks & Oikonomou (2018), em duas das revisões mais abrangentes desta literatura, convergem na conclusão de que a heterogeneidade metodológica, a ausência de métricas padronizadas e as dificuldades de identificação causal continuam a dificultar a comparação entre estudos e a deteção de efeitos que possam ser economicamente significativos a nível setorial.

Esta dissertação responde a estas três fragilidades: analisa os pilares ESG separadamente, combina econometria com Random Forest, e inclui uma análise de heterogeneidade setorial explícita. O foco no S&P 500 com dados da Refinitiv Eikon e uma janela de cinco anos, oferece um contexto metodologicamente controlado para testar estas abordagens.

Tabela 1 – Tabela-síntese da literatura empírica

Autor (Ano)	Amostra	Período	Método	Resultado principal
Nguyen et al. (2022)	S&P 500 não-financeiras	2018–2020	2SLS	ESG afeta positivamente ROA, ROE e Tobin's Q
Alfalih (2023)	S&P 500 não-financeiras	2010–2019	SYS-GMM	ESG positivo, mais forte em períodos de crescimento
Alareeni & Hamdan (2020)	S&P 500	2009–2018	Panel data	ESG positivo, sobretudo na dimensão social
De Roos (2023)	Europe Stoxx 600	2020–2022	Panel FE	ESG positivo sobre ROE; negativo sobre Tobin's Q
Hussain et al. (2024)	Top 100 empresas sauditas	2014–2021	GMM, FE, RE	Disclosure ESG melhora ROA, ROE e Tobin's Q (não-manufatura)
Jucá et al. (2024)	625 empresas, 29 países	2009–2020	Modelos hierárquicos	Controvérsias ESG reduzem ROE, sobretudo países desenvolvidos
Kim & Li (2021)	Empresas norte-americanas	1991–2013	Panel data	Governança influencia custo de capital
Vu et al. (2025)	23 mercados desenvolvidos	2004–2022	Análise de carteiras	Relação ESG–retorno fraca; condicionada pela atenção à sustentabilidade
Meehan & Corbet (2025)	Carteiras SRI vs SIN	Pré e durante COVID-19	Portfolio analysis	SRI mais resilientes em crise
Fatemi et al. (2018)	Empresas europeias	2006–2011	Panel data	Disclosure modera efeito ESG
Mio et al. (2023)	Utilities	—	Panel data	Governança reduz custo de capital próprio
Friede et al. (2015)	Meta-análise de 2 000+ estudos	1970–2014	Meta-análise	~63% positivo, ~10% negativo; restantes nulos
De Lucia et al. (2020)	Empresas públicas europeias	—	ML + Logit	ESG melhora desempenho financeiro
Parashar et al. (2024)	Empresas de energia limpa	—	K-means++	Relação ESG-ROE heterogénea por cluster
Zhou et al. (2021)	Empresas chinesas	—	Panel data	Apenas Governança reduz risco de crash

2.5 Conclusão da Revisão da Literatura

A literatura converge numa direção geral: o ESG tende a associar-se positivamente ao desempenho financeiro, mas diverge em quase tudo o resto: qual a dimensão

mais relevante, em que setores, com que métricas e em que condições. Esta divergência não é apenas ruído: reflete a complexidade real da relação e as limitações dos instrumentos usados para a medir. Esta tendência é consistente com a evidência agregada de Friede et al. (2015), cuja meta-análise de mais de 2000 estudos empíricos conclui que cerca de 63% reportam uma relação positiva entre ESG e desempenho financeiro.

Três padrões emergem com alguma consistência. Primeiro, a Governança é a dimensão com efeitos mais robustos e replicáveis, interpretada pelo mercado como sinal de estabilidade e redução de risco. Segundo, os benefícios do ESG são mais visíveis em contextos de crise e em horizontes temporais mais longos, o que coloca questões sobre o que se pode esperar detetar numa janela de cinco anos. Terceiro, a heterogeneidade setorial é real e relevante, o efeito médio esconde dinâmicas opostas entre indústrias.

Em síntese, a literatura evidencia a necessidade de abordagens que combinem rigor econométrico com métodos capazes de captar relações não lineares e heterogeneidade entre empresas e setores. É neste contexto que se enquadra a presente dissertação, procurando contribuir para este debate através da combinação de modelos econométricos em painel, técnicas de Machine Learning e análise setorial.

3 Metodologia

3.1 Enquadramento Metodológico – CRISP-DM

O presente estudo seguiu o modelo CRISP-DM (Cross Industry Standard Process for Data Mining), amplamente reconhecido como referência em projetos de análise de dados e Business Analytics. Este modelo permite estruturar o processo analítico em seis fases interdependentes: (i) compreensão do problema; (ii) compreensão dos dados; (iii) preparação dos dados; (iv) modelação; (v) avaliação; e (vi) comunicação dos resultados.

Compreensão do problema: Nesta fase foi definido o objetivo central do estudo, nomeadamente avaliar o impacto das práticas ESG no desempenho financeiro das empresas do índice S&P 500, bem como formular as hipóteses de investigação com base na revisão da literatura académica e empírica existente.

O estudo procurou compreender se o desempenho ESG está associado a diferenças na valorização de mercado e na rentabilidade das empresas.

Compreensão dos dados: Nesta fase foram analisadas as características das bases de dados ESG e financeiras obtidas através da plataforma Refinitiv Eikon, identificando variáveis relevantes, períodos de cobertura e eventuais limitações. Foram igualmente avaliadas a integridade, consistência e variabilidade das variáveis, de modo a garantir a adequação dos dados aos modelos analíticos utilizados. Adicionalmente, procedeu-se à análise exploratória dos dados, incluindo estatísticas descritivas e análise de correlações entre variáveis.

Preparação dos dados: A preparação dos dados incluiu os procedimentos de limpeza, transformação e integração das bases ESG e financeiras, assegurando consistência entre variáveis e coerência temporal. Foram criadas variáveis derivadas, como o logaritmo natural do total de ativos ($\ln \text{Assets}$) e o rácio de endividamento (Leverage), frequentemente utilizados na literatura como variáveis de controlo. As bases de dados foram posteriormente reorganizadas no formato “long” (empresa $\times$ ano), adequado à análise econométrica com dados em painel.

Modelação: A modelação é conduzida através de duas abordagens complementares. A primeira abordagem baseia-se em modelos econométricos de regressão linear com dados em painel, incluindo efeitos fixos de empresa e de ano. Estes modelos

permitem controlar heterogeneidade não observada entre empresas e choques macroeconómicos comuns ao longo do tempo, possibilitando a análise do impacto do desempenho ESG, tanto na sua forma agregada como através dos pilares *Environmental*, *Social* e *Governance* sobre indicadores de desempenho financeiro como Tobin's Q, ROA e ROE.

Complementarmente, é aplicado um modelo de aprendizagem automática baseado no algoritmo Random Forest. Este método permite capturar relações potencialmente não lineares entre variáveis e avaliar a importância relativa dos diferentes fatores explicativos no desempenho financeiro das empresas. A inclusão deste modelo permite complementar a análise econométrica tradicional com uma abordagem preditiva típica de projetos de Business Analytics.

A variável ESG Controversies foi considerada apenas na análise preditiva, com o objetivo de captar potenciais efeitos associados a eventos adversos de sustentabilidade, os quais podem não ser adequadamente captados por modelos econométricos lineares.

Avaliação: Os modelos econométricos foram avaliados quanto à sua validade estatística com base em métricas como o coeficiente de determinação (R^2), os testes t e F e a análise dos principais pressupostos do modelo linear, incluindo multicolinearidade, autocorrelação e heteroscedasticidade. Para esse efeito, foram utilizados indicadores como o Variance Inflation Factor (VIF) e testes específicos para dados em painel.

No caso do modelo Random Forest, a avaliação é realizada através de métricas de desempenho preditivo, bem como da análise da importância das variáveis (feature importance), permitindo identificar quais os fatores mais relevantes na explicação do desempenho financeiro.

Comunicação dos resultados: Por fim, os resultados obtidos foram apresentados sob a forma de tabelas e gráficos interpretativos, permitindo uma análise clara dos efeitos das práticas ESG. Esta fase incluiu também a discussão dos resultados à luz da literatura e a formulação de implicações práticas e recomendações futuras.

A adoção do modelo CRISP-DM permitiu assegurar uma abordagem sistemática, iterativa e orientada a dados, alinhada com as melhores práticas em

Business Analytics e com os princípios de rigor científico da investigação quantitativa.

3.2 Desenho da investigação

O estudo segue uma abordagem quantitativa e dedutiva: parte de teorias consolidadas sobre a relação entre ESG e desempenho financeiro e testa empiricamente a sua validade no contexto do S&P 500, com dados do período 2019–2023.

A estrutura de dados em painel, em que cada observação corresponde a uma empresa num determinado ano, constitui uma abordagem particularmente adequada para este tipo de questão de investigação. Permite capturar simultaneamente a variação entre empresas e a variação dentro da mesma empresa ao longo do tempo, controlando heterogeneidade não observada que seria problemática em modelos de corte transversal. Esta opção é consistente com os resultados do teste

de Hausman, que indicaram a preferência por especificações com efeitos fixos em detrimento de modelos de efeitos aleatórios. É também a estrutura que permite isolar o que realmente interessa: se uma empresa muda o seu desempenho ESG, isso associa-se a mudanças no seu desempenho financeiro?

As variáveis dependentes são o Tobin's Q, o ROA e o ROE, três métricas que captam dimensões distintas do desempenho. O Tobin's Q reflete as expectativas do mercado sobre o valor futuro da empresa; o ROA mede a eficiência operacional; o ROE avalia a rentabilidade para os acionistas. Por esse motivo, constitui uma métrica particularmente relevante para avaliar se a informação ESG é incorporada pelos investidores nas suas expectativas futuras. A utilização conjunta destas três métricas permite analisar se a relação entre ESG e desempenho financeiro se manifesta de forma distinta nas métricas contabilísticas e nas métricas baseadas no mercado, uma distinção que se revelará relevante na interpretação dos resultados.

As variáveis independentes principais são o ESG Combined Score e os três pilares individuais, Environmental, Social e Governance, analisados em especificações separadas para reduzir potenciais problemas de multicolinearidade e permitir uma comparação mais clara dos efeitos associados a cada dimensão ESG. O modelo inclui ainda variáveis de controlo para dimensão empresarial (lnAssets)

e alavancagem financeira (Leverage).

3.2.1 Hipóteses de Investigação

Três hipóteses orientam a análise empírica:

H1. A pontuação ESG agregada está positivamente associada ao desempenho financeiro, medido por Tobin's Q, ROA e ROE. Esta hipótese assenta na perspetiva dos *stakeholders* (Freeman, 1984) e na evidência de que práticas ESG robustas reduzem riscos operacionais e reputacionais (Nguyen et al., 2022; Giese et al., 2019).

H2. Os três pilares ESG têm efeitos heterogéneos sobre o desempenho financeiro, sendo a Governança a dimensão com associação mais robusta. Esta hipótese decorre da evidência consistente de que a qualidade da governação corporativa afeta diretamente o custo de capital e a confiança dos investidores (Kim & Li, 2021; Mio et al., 2023).

H3. A relação entre ESG e desempenho financeiro contém componentes não lineares, podendo ser captada de forma mais eficaz por modelos de aprendizagem automática do que por especificações lineares com efeitos fixos. Esta hipótese baseia-se na evidência recente sobre a utilidade de técnicas de Machine Learning para identificar padrões complexos em dados ESG (De Lucia et al., 2020; Kaminskyi & Nehrey, 2023; Parashar et al., 2024). Do ponto de vista económico, a não-linearidade é plausível na medida em que os benefícios das práticas ESG podem manifestar-se apenas a partir de determinados limiares de desempenho, exibir retornos marginais decrescentes em empresas já bem posicionadas, ou depender de interações com características da empresa e do setor.

H1 e H2 são testadas através dos modelos econométricos com efeitos fixos; H3 é avaliada pela comparação entre os resultados econométricos e os resultados preditivos do Random Forest. A heterogeneidade implícita em H2 é ainda explorada na análise setorial da secção 4.5.

3.3 Amostra e Dados

A amostra do presente estudo é composta pelas empresas que integraram o índice S&P 500 no período compreendido entre 2019 e 2023. Este índice foi selecionado por representar um dos conjuntos empresariais mais relevantes e estáveis do

mercado financeiro global, refletindo de forma abrangente o desempenho das maiores empresas cotadas nos Estados Unidos da América. A escolha do S&P 500 justifica-se, igualmente, pela ampla disponibilidade de dados financeiros e não financeiros, bem como pela representatividade de diferentes setores económicos, o que contribui para uma análise mais robusta e generalizável.

Os dados utilizados foram obtidos a partir da base de dados Refinitiv Eikon, disponibilizada pela biblioteca do ISCTE Business School. A amostra foi construída a partir da composição do índice S&P 500 reportada na Refinitiv Eikon, tendo-se recolhido os dados das empresas constituintes para o período 2019–2023, o que resultou num painel equilibrado de 503 entidades (correspondentes a 500 empresas, dada a existência de classes de ações múltiplas). Esta plataforma fornece indicadores financeiros padronizados e métricas ESG reconhecidas internacionalmente, garantindo consistência e comparabilidade entre empresas e períodos. A utilização do Eikon permite aceder aos scores ESG consolidados e desagregados (pilares ambiental, social e de governação), bem como aos principais indicadores financeiros necessários à análise do desempenho económico.

Foram recolhidos dados referentes às seguintes variáveis:

- ESG Combined Score (pontuação agregada ajustada por controvérsias);
- Environmental, Social e Governance Pillar Scores (pontuações individuais de cada dimensão ESG);
- ESG Controversies Score (indicador que mede a exposição a incidentes negativos de sustentabilidade);
- Return on Assets (ROA) e Return on Equity (ROE) como medidas de desempenho financeiro;

Total Assets, Total Debt e Total Equity, utilizados no cálculo de variáveis de controlo, nomeadamente tamanho da empresa e nível de endividamento.

Os dados foram extraídos em formato anual (fiscal years FY0–FY-4, correspondentes aos anos de 2023 a 2019), garantindo a consistência temporal

entre as variáveis ESG e financeiras. Após a recolha, procedeu-se à limpeza e transformação dos ficheiros, unindo as bases de dados ESG e Financeira através do identificador RIC (Reuters Instrument Code), comum a todas as observações. Foram posteriormente eliminadas observações com dados em falta ou inconsistentes, de modo a assegurar a fiabilidade da amostra final. Importa ainda sublinhar que a janela temporal analisada (2019–2023) integra o período da pandemia de COVID-19, um choque exógeno que afetou simultaneamente as valorizações de mercado, a rentabilidade e, potencialmente, a divulgação e os scores ESG das empresas. Este facto deve ser tido em conta na interpretação dos resultados, na medida em que pode introduzir ruído na relação estimada entre desempenho ESG e desempenho financeiro, e é retomado nas limitações do estudo.

A amostra resultante é composta por aproximadamente 500 empresas, totalizando cerca de 2500 observações anuais, o que permite aplicar técnicas econométricas apropriadas a dados em painel e obter resultados estatisticamente robustos.

3.4 Variáveis e Modelo Econométrico

3.4.1 Variáveis e Expectativas Teóricas

A Tabela 2 apresenta a descrição das variáveis utilizadas no modelo, incluindo variáveis dependentes, independentes e de controlo, bem como os respetivos sinais esperados com base na literatura.

Tabela 2 – Descrição das variáveis utilizadas no estudo

Tipo	Variável	Símbolo	Definição	Sinal	Fonte	Suporte Teórico
Dependente	Return on Assets	ROA	Lucro líquido dividido pelo total de ativos; mede a eficiência operacional.	N/A	Refinitiv Eikon	
Dependente	Return on Equity	ROE	Lucro líquido dividido pelo capital próprio; mede a rentabilidade para os acionistas.	N/A	Refinitiv Eikon	
Dependente	Tobin's Q	TQ	Rácio entre a capitalização bolsista da empresa e o total de ativos; mede a valorização de mercado relativamente ao valor contabilístico dos ativos.	N/A	Refinitiv Eikon	
Independente principal	ESG Combined Score	ESG	Pontuação agregada de desempenho ambiental, social e de governação (0–100).	+	Refinitiv Eikon	Nguyen et al. (2022); Giese et al. (2019)
Independente	Environmental Score	E	Desempenho em políticas e práticas ambientais.	+	Refinitiv Eikon	Hussain et al. (2024)
Independente	Social Score	S	Desempenho em questões sociais e de capital humano.	+	Refinitiv Eikon	Bustillo-Castillejo et al. (2023)
Independente	Governance Score	G	Qualidade da governação corporativa e práticas de gestão.	+	Refinitiv Eikon	Kim & Li (2021); Mio et al. (2023)
Controlo	Tamanho da Empresa (lnAssets)	lnAssets	Logaritmo natural do total de ativos (proxy de tamanho).	+/-	Refinitiv Eikon	(controlo)
Controlo	Endividamento (Leverage)	Leverage	Rácio entre dívida total e ativo total (proxy de alavancagem financeira).	—	Refinitiv Eikon	(controlo)
Controlo	ESG Controversies	Controversies	Score de controvérsias; valores altos indicam ausência de incidentes. Variável incluída na análise preditiva (Random Forest)	+	Refinitiv Eikon	Cohen (2023); Jucá et al. (2024)

Fonte: Elaboração própria com base em dados da Refinitiv Eikon.

Nota: Sinais positivos (+) indicam relação direta esperada com o desempenho financeiro; sinais negativos (-) indicam relação inversa. Variáveis dependentes (ROA, ROE, Tobin's Q) não têm sinal esperado pois constituem o regressando, não regressores. Controversies tem sinal positivo esperado porque, na escala da Refinitiv, valores altos indicam ausência de incidentes negativos.

Conforme resumido na Tabela 2, as variáveis selecionadas permitem avaliar o impacto das práticas de sustentabilidade empresarial, mensuradas através dos indicadores ESG, sobre o desempenho financeiro das empresas que compõem o índice S&P 500.

As variáveis utilizadas foram obtidas a partir da base de dados Refinitiv Eikon,

abrangendo o período de 2019 a 2023. O objetivo principal é compreender se o desempenho ESG, em termos agregados e por dimensão (E, S e G), influencia o desempenho financeiro das empresas, medido por indicadores contabilísticos e de mercado.

Variáveis dependentes

O desempenho financeiro das empresas é medido através de três indicadores: Return on Assets (ROA), Return on Equity (ROE) e Tobin's Q. O ROA reflete a eficiência operacional, captando a capacidade de a empresa gerar lucros a partir dos ativos totais; o ROE avalia a rentabilidade para os acionistas, considerando o capital próprio investido. Complementarmente, o Tobin's Q constitui uma métrica de desempenho baseada no mercado, refletindo a relação entre a valorização bolsista da empresa e o valor contabilístico dos seus ativos, incorporando as expectativas dos investidores relativamente ao desempenho futuro e à criação de valor.

Operacionalmente, o Tobin's Q foi aproximado nesta dissertação pelo rácio entre a capitalização bolsista de mercado e o valor contabilístico do total de ativos, no final de cada exercício fiscal:

$$Tobin's Q_{it} = \frac{\text{Market Cap}_{it}}{\text{Total Assets}_{it}}$$

onde Market Cap corresponde ao preço da ação multiplicado pelo número de ações em circulação no final do exercício. Importa esclarecer que esta formulação constitui uma aproximação simplificada (*market-to-assets*), que utiliza apenas o valor de mercado do capital próprio no numerador. Difere, por isso, da proxy clássica de Chung & Pruitt (1994), que adiciona ao numerador o valor contabilístico da dívida, $q \approx (\text{Valor de mercado do capital próprio} + \text{Dívida}) / \text{Total de ativos}$. Optou-se pela versão simplificada por requerer apenas dados de mercado e contabilísticos de acesso direto e por ser amplamente utilizada como medida de valorização relativa de mercado. Reconhece-se, contudo, que a omissão da dívida no numerador implica que a medida capta sobretudo a valorização do capital próprio relativamente ao ativo total, devendo os resultados ser interpretados à luz desta simplificação. Dado que o nível de endividamento é controlado de forma independente através da variável Leverage, atenua-se parcialmente a omissão da dívida.

Estes indicadores são amplamente utilizados na literatura empírica sobre ESG e desempenho financeiro (Nguyen et al., 2022; Zhou et al., 2022). Estes permitem capturar diferentes perspectivas da performance empresarial, operacional e de criação de valor para o acionista.

Variáveis independentes

As variáveis independentes principais correspondem aos indicadores ESG Combined Score e aos três pilares ESG: Ambiental (E), Social (S) e de Governança (G).

O ESG Combined Score representa a pontuação agregada que sintetiza o desempenho da empresa em práticas ambientais, sociais e de governança. Já os pilares individuais permitem uma análise mais detalhada do contributo de cada dimensão para o desempenho financeiro.

Estes indicadores permitem avaliar separadamente os efeitos ambientais, sociais e de governança, além de uma métrica composta que integra as três dimensões.

De acordo com a literatura, espera-se uma relação positiva entre as pontuações ESG e o desempenho financeiro, uma vez que empresas com práticas sustentáveis tendem a apresentar maior eficiência operacional e menor exposição ao risco (Giese et al., 2019; Mio et al., 2023).

Variáveis de controlo

Para reduzir a possibilidade de viés e isolar o impacto específico das práticas ESG, o modelo inclui variáveis de controlo amplamente utilizadas em estudos semelhantes.

O tamanho da empresa ($\ln\text{Assets}$) é medido pelo logaritmo natural do total de ativos e procura capturar economias de escala e a capacidade de absorver custos associados à sustentabilidade.

O nível de endividamento (Leverage), calculado como o rácio entre dívida total e ativo total, controla o efeito da estrutura de capital sobre o desempenho.

Por fim, o ESG Controversies Score reflete a existência (ou ausência) de incidentes reputacionais, sendo esperado um impacto positivo nas empresas com menos controvérsias.

Estas variáveis de controlo permitem isolar o efeito específico das práticas ESG

sobre o desempenho financeiro, reduzindo potenciais problemas de viés por variável omitida, uma vez que o tamanho empresarial e a estrutura de capital influenciam simultaneamente a capacidade de adoção de práticas ESG e os indicadores de desempenho económico-financeiro.

Deste modo, o modelo econométrico foi estimado através de regressões lineares com dados em painel, captando simultaneamente variações temporais e transversais entre empresas, conforme detalhado na próxima subsecção.

3.4.2 Procedimentos de Análise de Dados

A análise empírica desta investigação recorre a modelos de regressão linear múltipla com dados em painel, de forma a avaliar o impacto das práticas de sustentabilidade empresarial (ESG) sobre o desempenho financeiro das empresas do índice S&P 500 no período de 2019 a 2023.

A regressão linear múltipla permite estimar a relação entre uma variável dependente e várias variáveis explicativas, mantendo constantes os restantes fatores. A sua formulação geral pode ser representada da seguinte forma:

$$Y_{it} = \beta_0 + \beta_1 X_{1it} + \beta_2 X_{2it} + \dots + \beta_k X_{kit} + \varepsilon_{it}$$

onde:

- Y_{it} representa a variável dependente para a empresa i no período t (neste caso,

Tobin's Q, ROA ou ROE);

- X_{kit} representa as variáveis independentes e de controlo (ESG, Ambiental, Social, Governação, InAssets, Leverage e Controvérsias);

- β_k são os parâmetros a estimar, que medem o efeito marginal de cada variável explicativa sobre o desempenho financeiro;

- ε_{it} é o termo de erro, que capta fatores não observados.

3.4.2.1 Pressupostos do Modelo de Regressão Linear

Para que as estimativas obtidas através do método dos mínimos quadrados ordinários (OLS) sejam válidas e não enviesadas, devem ser respeitados os pressupostos clássicos do modelo linear geral, conforme o Teorema de Gauss-Markov (Wooldridge, 2020). Estes pressupostos garantem que os estimadores obtidos são Best Linear Unbiased Estimators (BLUE), ou seja, os melhores estimadores lineares não enviesados.

Os principais pressupostos são os seguintes:

1. Linearidade dos parâmetros

A relação entre a variável dependente e as variáveis explicativas deve ser linear nos parâmetros.

Isto significa que o modelo pode incluir transformações nas variáveis (como logaritmos ou termos quadráticos), desde que continue linear nos coeficientes β .

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

2. Amostra aleatória e independência das observações

As observações devem constituir uma amostra aleatória representativa da população. Nos modelos com dados em painel, é essencial garantir que os erros são independentes entre empresas e ao longo do tempo, ou seja, que não existe autocorrelação serial entre os resíduos.

3. Ausência de multicolinearidade perfeita

Nenhuma variável independente deve ser uma combinação linear exata de outras variáveis explicativas. A colinearidade perfeita inviabiliza a estimação do modelo, uma vez que impede o cálculo da inversa da matriz. Mesmo quando não é perfeita, uma multicolinearidade elevada pode inflacionar as variâncias dos coeficientes, reduzindo a precisão estatística das estimativas. A existência de multicolinearidade foi verificada através da análise do Variance Inflation Factor (VIF).

4. Valor esperado do erro condicional é nulo

O termo de erro deve ter valor esperado nulo, dado o comportamento das variáveis explicativas:

$$E(\varepsilon_i | X_1, X_2, \dots, X_k) = 0$$

Isto significa que os erros não estão correlacionados com as variáveis independentes. A violação deste pressuposto pode resultar de omissão de variáveis relevantes, endogeneidade ou erros de medição, levando a estimadores viesados e inconsistentes.

5. Homocedasticidade dos erros

A variância do termo de erro deve ser constante para todas as observações:

$$Var(\varepsilon_i | X_1, X_2, \dots, X_k) = \sigma^2$$

Quando a variância do erro não é constante (heterocedasticidade), os estimadores OLS permanecem não viesados, mas deixam de ser eficientes, comprometendo a validade da inferência estatística. Neste caso, foram utilizados erros-padrão robustos para corrigir o problema e garantir resultados consistentes.

6. Normalidade dos resíduos

Os resíduos devem seguir uma distribuição normal:

$$\varepsilon_i \sim N(0, \sigma^2)$$

Este pressuposto é particularmente importante em amostras pequenas, pois assegura a validade dos testes t e F e dos intervalos de confiança.

3.4.2.2 Verificação dos Pressupostos

A adequação dos pressupostos foi avaliada com recurso aos seguintes testes estatísticos:

- Multicolinearidade: análise do *Variance Inflation Factor (VIF)*;
- Heterocedasticidade: *Teste de Breusch–Pagan*;
- Autocorrelação: *Teste de Durbin–Watson* (ou *Teste de Wooldridge* para dados em painel);
- Normalidade dos resíduos: *Teste de Jarque–Bera*.

O cumprimento destes pressupostos assegura a robustez, consistência e validade estatística das estimativas obtidas pelos modelos de regressão linear múltipla aplicados nesta investigação.

3.4.2.3 **Avaliação e Validação dos Modelos**

A qualidade e robustez dos modelos econométricos foram avaliadas com base nas seguintes métricas e testes estatísticos:

- Coeficiente de determinação (R^2 e R^2 ajustado): mede a proporção da variação explicada pelo modelo, sendo o R^2 ajustado mais adequado para comparações entre modelos com diferente número de variáveis explicativas;
- Teste F: avalia a significância global do modelo, testando se todos os coeficientes, exceto o intercepto, são simultaneamente iguais a zero;
- Testes t individuais: verificam a significância estatística de cada variável explicativa de forma isolada;
- Sinais e magnitudes dos coeficientes: foram interpretados de acordo com as expectativas teóricas definidas na Tabela 2 e com base na literatura empírica.

3.4.2.4 **Tratamento de Dados e Software Utilizado**

Os dados foram extraídos e tratados na plataforma Refinitiv Eikon e posteriormente trabalhados em Python (Google Colab), com recurso às bibliotecas *pandas*, *statsmodels* e *linearmodels*. O processo incluiu a limpeza e normalização das bases de dados ESG e financeiras, bem como a fusão dos ficheiros com base nos identificadores das empresas.

Procedeu-se também à criação de variáveis de controlo, à verificação de valores em falta e à transformação logarítmica do total de ativos para obtenção do *lnAssets*.

Na estimação dos modelos, foram considerados efeitos fixos por empresa e efeitos de tempo, de modo a capturar heterogeneidades não observáveis e variações temporais.

Para reforçar a validade dos resultados, foram ainda realizados testes adicionais de diagnóstico, nomeadamente:

- *Teste de Hausman*, para determinar a adequação entre efeitos fixos e efeitos aleatórios;

- *Teste de heterocedasticidade de Breusch–Pagan;*
- *Análise de multicolinearidade através do VIF;*
- *Teste de normalidade dos resíduos (Jarque–Bera).*

3.5 Tratamento e Análise dos Dados

Os dados recolhidos foram tratados e analisados com recurso ao software Python, através da plataforma Google Colab, que permite a execução de código em ambiente de nuvem. Esta escolha justifica-se pela flexibilidade na manipulação de dados e pela capacidade de integração de múltiplas bibliotecas estatísticas, adequadas à análise quantitativa de dados em painel.

A análise empírica baseia-se num conjunto de dados consolidado, previamente estruturado no formato de painel, em que cada observação corresponde a uma empresa num determinado ano fiscal, abrangendo o período de 2019 a 2023. Este dataset integra informação ESG e financeira proveniente da base de dados Refinitiv Eikon, garantindo consistência temporal e comparabilidade entre empresas.

Após a consolidação da base de dados, procedeu-se à validação da estrutura de dados em painel, assegurando a inexistência de observações duplicadas por empresa e ano. As variáveis quantitativas foram convertidas para formato numérico e avaliadas quanto à presença de valores em falta. Observações com missing values nas variáveis utilizadas na modelação foram removidas através de listwise deletion, resultando na exclusão de até cerca de 8% da amostra inicial, consoante o modelo estimado. Esta abordagem assegura consistência entre os modelos econométricos e preditivos, sem comprometer a representatividade da amostra final.

Foram ainda consideradas variáveis derivadas, nomeadamente o logaritmo natural do total de ativos ($\ln\text{Assets}$), utilizado como proxy para o tamanho da empresa, e o rácio de endividamento (Leverage), calculado como a razão entre a dívida total e o ativo total, representando o grau de alavancagem financeira.

Seguidamente, realizou-se uma análise descritiva das principais variáveis do estudo (ESG, Environmental, Social, Governance, ROA, ROE, Tobin's Q, $\ln\text{Assets}$ e Leverage), incluindo medidas de tendência central e dispersão, com o objetivo de caracterizar o comportamento médio das empresas da amostra e identificar potenciais outliers. Para uma análise preliminar das relações entre variáveis, foram igualmente calculadas matrizes de correlação de Pearson.

De forma a testar as hipóteses de investigação, aplicaram-se modelos de regressão linear múltipla com dados em painel, recorrendo ao pacote `linearmodels` do Python. Os modelos foram estimados com erros-padrão robustos e incluem efeitos fixos de empresa e ano, de modo a controlar variações temporais comuns às empresas ao longo do período de análise. A estimação dos parâmetros foi realizada através do método dos mínimos quadrados ordinários (OLS) avaliando-se a significância estatística dos coeficientes aos níveis de 1%, 5% e 10%.

Paralelamente, foi aplicada uma abordagem de Machine Learning baseada no algoritmo Random Forest Regression, com o objetivo de complementar a análise econométrica tradicional e avaliar a capacidade preditiva das métricas ESG relativamente ao desempenho financeiro. Os resultados obtidos foram posteriormente exportados em formato tabular e sintetizados em tabelas e gráficos interpretativos, apresentados no capítulo seguinte.

A avaliação dos modelos econométricos baseou-se na análise dos coeficientes estimados, valores-p e no coeficiente de determinação (R^2), enquanto os modelos preditivos foram avaliados com base em métricas de erro e capacidade explicativa, assegurando transparência, rigor metodológico e reprodutibilidade da análise.

3.6 Modelação Preditiva com Random Forest

Esta abordagem enquadra-se na fase de modelação do framework CRISP-DM e permite captar relações não lineares e interações complexas entre variáveis, que podem não ser adequadamente modeladas por regressões lineares múltiplas.

O algoritmo Random Forest baseia-se na construção de um conjunto de árvores de decisão independentes, combinadas através de um mecanismo de agregação (*ensemble learning*), permitindo reduzir problemas de sobreajustamento e aumentar a capacidade de generalização dos modelos. A sua utilização é particularmente adequada em contextos empresariais e financeiros, onde as relações entre variáveis podem ser não lineares e heterogéneas.

No âmbito deste estudo, foram estimados modelos de Random Forest distintos, considerando como variáveis dependentes o Return on Assets (ROA), o Return on Equity (ROE) e o Tobin's Q. Esta abordagem permite comparar o poder explicativo das métricas ESG tanto em indicadores contabilísticos como numa medida de desempenho baseada no mercado, avaliando se o impacto das práticas ESG é captado de forma diferenciada pelos investidores.

As variáveis explicativas incluídas nos modelos de Random Forest correspondem ao ESG Combined Score, aos pilares Environmental, Social e Governance, bem como às variáveis de controlo relacionadas com o tamanho da empresa (LnAssets), o nível de endividamento (Leverage) e as controvérsias ESG. De forma a evitar problemas de data leakage, variáveis diretamente relacionadas com a construção do Tobin's Q, como a capitalização bolsista, foram excluídas dos modelos preditivos. Para avaliar o desempenho dos modelos, os dados foram divididos em conjuntos de treino e teste, permitindo analisar a capacidade de generalização dos algoritmos. A qualidade preditiva foi avaliada com base em métricas como o erro quadrático médio (RMSE), o erro absoluto médio (MAE) e o coeficiente de determinação (R^2). Adicionalmente, foi analisada a importância relativa das variáveis explicativas, possibilitando a identificação das dimensões ESG com maior contributo para a previsão do desempenho financeiro.

A inclusão do Random Forest como técnica complementar aos modelos econométricos permite reforçar a robustez dos resultados obtidos, oferecendo uma perspetiva preditiva adicional e contribuindo para uma compreensão mais abrangente do impacto das práticas ESG no desempenho financeiro das empresas do índice S&P 500.

Para garantir a robustez dos resultados, foram adotados três refinamentos metodológicos relativamente à implementação base. Em primeiro lugar, os hiperparâmetros do Random Forest foram ajustados via GridSearchCV com validação cruzada de 5-folds, explorando combinações de número de árvores (300 e 500), profundidade máxima (sem limite e 15) e número mínimo de observações por folha (3 e 7), com a configuração ótima sendo selecionada com base no R^2 médio em validação cruzada. Em segundo lugar, foram estimados modelos separados para a especificação agregada (com ESG Combined Score) e desagregada (com os pilares E, S e G), evitando a partilha de variância explicada entre as duas e permitindo uma comparação direta do valor preditivo de cada conceptualização. Em terceiro lugar, a robustez temporal foi avaliada através de uma divisão treino-teste cronológica (treino: 2019–2022; teste: 2023), em complemento à divisão aleatória 80/20, simulando um cenário de previsão para um período totalmente fora da amostra de treino. Adicionalmente, a importância das variáveis foi quantificada via *permutation importance*, métrica mais robusta do que a Mean Decrease Impurity (MDI) por ser invariante à cardinalidade das variáveis explicativas (Strobl et al., 2007).

Importa notar que o ESG Combined Score da Refinitiv já incorpora um ajustamento por controvérsias. Nos modelos agregados, a inclusão simultânea desta variável e do score de Controversies implica alguma sobreposição informativa nesta dimensão, ausente nos modelos por pilares (que utilizam os scores individuais não ajustados). Esta assimetria reforça, ainda assim, a leitura principal: apesar de o modelo agregado dispor de informação de controvérsias potencialmente redundante, continua a ser superado pela especificação desagregada.

3.7 Estatísticas Descritivas e Análise Exploratória

Antes da estimação dos modelos econométricos, procede-se à análise estatística descritiva das principais variáveis incluídas no estudo. Esta etapa permite caracterizar a amostra, compreender a distribuição dos dados e identificar padrões relevantes que possam influenciar os resultados das análises subsequentes. De forma a reduzir a influência de valores extremos nas variáveis financeiras, foi aplicada uma winsorização aos percentis de 1% e 99%, em linha com a prática comum na literatura empírica em finanças (Fahlenbrach et al., 2018).

A Tabela 3 apresenta as estatísticas descritivas das variáveis utilizadas no estudo para o período 2019–2023. As estatísticas são calculadas sobre os casos disponíveis para cada variável (available-case), pelo que o N varia entre variáveis; os modelos econométricos utilizam a amostra após listwise deletion, o que explica diferenças residuais nos N reportados nas tabelas de resultados.

Tabela 3 – Estatísticas descritivas das variáveis do estudo

	Média	Mediana	Desv_Padrão	Mínimo	Máximo	N
TobinQ	2,6009	1,7381	2,52	0,1433	13,623	2460
ROA	0,073	0,0578	0,0779	-0,1677	0,3167	2506
ROE	0,2876	0,162	0,5894	-0,6056	4,4949	2362
ESG	58,6227	60,2786	15,3481	10,8315	92,3787	2474
Environmental	60,3887	64,8112	21,9176	0	97,8806	2474
Social	68,4198	71,3314	16,789	12,8833	97,6802	2474
Governance	64,115	66,9319	19,3867	1,0706	99,467	2474
InAssets	24,0691	23,9654	1,3075	21,2833	27,8076	2511
Leverage	0,2979	0,2811	0,1961	0	1,0107	2511

Observa-se que o Tobin's Q apresenta média de 2,60 e mediana de 1,74,

evidenciando assimetria positiva na distribuição. O valor máximo de 13,62 indica a presença de empresas com níveis de valorização de mercado superiores à média, fenómeno comum em amostras de grandes empresas cotadas.

Relativamente às métricas de rentabilidade, o ROA apresenta média de 7,3%, enquanto o ROE apresenta média de 28,8%, com mediana substancialmente inferior (16,2%), indicando dispersão na rentabilidade dos capitais próprios entre as empresas da amostra.

No que respeita ao desempenho ESG, o score agregado apresenta média de 58,62 pontos, com variação considerável (desvio-padrão de 15,35). Entre os pilares, destaca-se a dimensão Social com média mais elevada (68,42), seguida das dimensões Governance (64,12) e Environmental (60,39), sugerindo diferentes níveis de desempenho nas dimensões avaliadas.

A variável *InAssets* apresenta menor dispersão relativa, refletindo a transformação logarítmica aplicada ao total de ativos. Por sua vez, a variável *Leverage* apresenta média de 0,30, indicando níveis moderados de endividamento entre as empresas analisadas.

Importa ainda referir que, de forma a mitigar a influência de valores extremos nas variáveis financeiras, foi aplicada uma winsorização aos percentis de 1% e 99%, procedimento comum na literatura empírica em finanças para reduzir o impacto de outliers nas análises econométricas.

No seu conjunto, as estatísticas descritivas revelam heterogeneidade significativa tanto na valorização de mercado como no desempenho financeiro e ESG das empresas analisadas, justificando a aplicação de modelos de dados em painel com efeitos fixos de empresa e de período.

3.7.1 Matriz de Correlação

Tabela 4 – Matriz de Correlação

	Tobin Q	ROA	ROE	ESG	Environment al	Social	Governanc e	InAsset s	Leverag e
TobinQ	1								
ROA	0,563	1							
ROE	0,258	0,442	1						
ESG	-0,13	-0,04	0,050	1					
Environmenta l	-0,191	-0,078	0,021	0,533	1				
Social	-0,115	-0,043	0,042	0,531	0,628	1			
Governance	-0,163	-0,027	0,055	0,475	0,279	0,203	1		
InAssets	-0,498	-0,332	-0,111	-0,042	0,342	0,277	0,135	1	
Leverage	0,036	-0,045	0,155	0,116	0,172	0,105	0,034	-0,06	1

Nota: Coeficientes de correlação de Pearson calculados sobre as variáveis após winsorização aos percentis de 1% e 99%, conforme descrito na secção 3.5.

Observa-se uma correlação positiva moderada entre Tobin's Q e ROA ($\rho = 0,563$; $p < 0,001$), sugerindo que empresas com maior rentabilidade operacional tendem a apresentar níveis mais elevados de valorização de mercado. Este resultado é consistente com a literatura financeira, que associa melhor desempenho operacional a avaliações de mercado mais favoráveis.

Relativamente às variáveis ESG, verifica-se uma correlação negativa, embora de baixa magnitude, entre o score ESG agregado e o Tobin's Q ($\rho = -0,130$) e entre ESG e ROA ($\rho = -0,040$), bem como uma correlação positiva muito ligeira entre ESG e ROE ($\rho = 0,050$). Estes resultados sugerem que, numa análise preliminar, não se observa uma associação linear forte entre o desempenho ESG e o desempenho financeiro das empresas da amostra.

Como esperado, o score ESG apresenta correlações moderadas com os seus pilares individuais, nomeadamente Environmental ($\rho = 0,533$), Social ($\rho = 0,531$) e Governance ($\rho = 0,475$), refletindo a natureza composicional do indicador ESG agregado. Adicionalmente, observa-se uma correlação relativamente mais elevada entre os pilares Environmental e Social ($\rho = 0,628$), o que é consistente com a proximidade conceptual entre estas dimensões nas práticas de sustentabilidade empresarial.

No que respeita às variáveis de controlo, observa-se uma correlação negativa relativamente forte entre InAssets e Tobin's Q ($\rho = -0,498$; $p < 0,001$) e também entre InAssets e ROA ($\rho = -0,332$; $p < 0,001$), indicando que empresas de maior dimensão tendem a apresentar menor valorização relativa

de mercado e menor rentabilidade operacional. A variável Leverage apresenta correlação positiva moderada com o ROE ($\rho = 0,155$) e correlações geralmente fracas com as restantes variáveis do modelo.

Os coeficientes de correlação observados não indicam níveis excessivamente elevados de associação entre as variáveis explicativas. Embora se verifiquem correlações moderadas entre alguns pilares ESG, estes valores permanecem abaixo dos níveis tipicamente associados a problemas severos de multicolinearidade. Esta conclusão é posteriormente confirmada através da análise do Variance Inflation Factor (VIF).

4 Resultados e Discussão

4.1 Resultados das Regressões Lineares (Modelos Econométricos)

4.1.1 Modelos OLS

Numa primeira fase estimaram-se modelos OLS como benchmark comparativo, incluindo o ESG agregado (ou os pilares), InAssets e Leverage. Os coeficientes ESG não são estatisticamente significativos em nenhuma especificação, mas este resultado tem valor limitado, porque o OLS não controla heterogeneidade não observada entre empresas nem efeitos temporais comuns. Os modelos com efeitos fixos, apresentados a seguir, constituem a abordagem principal.

4.1.2 Modelos de Painel com Efeitos Fixos

A análise principal usa modelos de painel com efeitos fixos de empresa e de ano, estimados com erros-padrão clusterizados por empresa, uma especificação que isola a variação intraempresa e é robusta a heterocedasticidade e autocorrelação dentro de cada empresa.

Tabela 5 – Resultados das Regressões em Painel com Efeitos Fixos (FE)

	(1) TobinQ ESG	(2) TobinQ Pilares	(3) ROA ESG	(4) ROA Pilares	(5) ROE ESG	(6) ROE Pilares
ESG	0,0006 (0,0023)	—	-0,0001 (0,0002)	—	0,0013 (0,0012)	—
Environ mental	—	-0,0061 (0,0050)	—	-0,0002 (0,0002)	—	0,0007 (0,0011)
Social	—	-0,0023 (0,0046)	—	0,0001 (0,0003)	—	-0,0004 (0,0015)
Governa nce	—	-0,0051* (0,0026)	—	0,0000 (0,0001)	—	0,0011 (0,0008)
InAssets	-1,2410*** (0,3676)	-1,2022*** (0,3698)	-0,0253 (0,0170)	-0,0246 (0,0172)	-0,1469 (0,1027)	-0,1470 (0,1050)
Leverage	0,0814 (0,7841)	0,0974 (0,7872)	-0,2278*** (0,0529)	-0,2285*** (0,0528)	0,1406 (0,3719)	0,1384 (0,3703)
Observa ções	2448	2448	2474	2474	2334	2334
R² within	0,0745	0,0829	0,0406	0,0403	0,0000	0,0008
FE Empresa	Sim	Sim	Sim	Sim	Sim	Sim
FE Ano	Sim	Sim	Sim	Sim	Sim	Sim

Nota: *** p < 0,01; ** p < 0,05; * p < 0,10. Erros-padrão entre parênteses.

(1) Tobin's Q — ESG agregado

O coeficiente do ESG não é estatisticamente significativo, o que indica que variações anuais no score ESG não se refletem de forma sistemática na valorização de mercado ao longo de 2019–2023. O resultado que se destaca é o do *InAssets*: negativo e significativo a 1%, sugerindo que empresas de maior dimensão são avaliadas a múltiplos mais baixos, consistente com a ideia de que o mercado lhes atribui menor potencial de crescimento relativo. O endividamento não apresenta efeito significativo.

(2) Tobin's Q — Pilares ESG

Desagregar o score ESG nos três pilares não altera o quadro. Nenhuma das dimensões atinge significância estatística, o que indica que o mercado não distingue, pelo menos no curto prazo e em termos de variação intraempresa, melhorias numa dimensão específica do desempenho ESG. O pilar de Governança apresenta um coeficiente marginalmente significativo a 10% ($-0,0051^*$), o que, pela sua fragilidade entre especificações, não altera a conclusão geral. O efeito do *InAssets* mantém-se negativo e significativo. Estes resultados não fornecem suporte para a hipótese H1.

Vale notar que o coeficiente da Governance tem sinal negativo, contrariando a expectativa de H2. Uma possível explicação prende-se com os custos de conformidade associados a práticas mais exigentes de governação corporativa, incluindo auditorias externas, estruturas de supervisão independentes e requisitos acrescidos de divulgação de informação. Embora estas práticas possam gerar benefícios de longo prazo através da redução do risco e do reforço da confiança dos investidores, os seus custos são frequentemente imediatos, podendo exercer pressão sobre a valorização de mercado no curto prazo. Esta interpretação é particularmente plausível no contexto do S&P 500, onde os níveis médios de governação já são elevados e melhorias marginais podem refletir sobretudo custos adicionais de compliance.

(3) e (4) ROA — ESG agregado e Pilares

Substituindo o Tobin's Q pelo ROA, os coeficientes ESG continuam não significativos, tanto no modelo agregado como no desagregado por pilares. O

resultado que efetivamente emerge é o do endividamento: Leverage apresenta um coeficiente negativo e significativo a 1% em ambas as especificações, confirmando que empresas mais alavancadas tendem a registar menor rentabilidade operacional. É um resultado bem documentado na literatura e que aqui se reproduz com consistência. Também neste caso não se observa evidência empírica que suporte H1.

(5) e (6) ROE — ESG agregado e Pilares

No ROE, o padrão repete-se: nem o ESG agregado nem qualquer pilar individual produz um efeito distinguível de zero, e as variáveis de controlo também não atingem significância. Os R^2 within de 0,0000 e 0,0008 nos modelos (5) e (6) indicam que os regressores incluídos praticamente não explicam a variação intraempresa desta métrica.

Este resultado não é surpreendente. O ROE tem um desvio-padrão de 0,589 após winsorização (cf. Tabela 3) e a amostra inclui empresas com capital próprio reduzido ou negativo, situações em que esta métrica perde estabilidade económica. Por esta razão, o ROE é mantido nos modelos econométricos por comparabilidade com a literatura, mas os resultados principais da dissertação devem ser lidos sobretudo à luz do Tobin's Q e do ROA.

Antes de avançar, vale a pena clarificar o que estes modelos estimam: a relação entre *variações* anuais nos scores ESG e *variações* nas métricas financeiras, dentro da mesma empresa. Ausência de significância estatística não significa que o ESG seja irrelevante, significa que, neste período e com esta estrutura de dados, as mudanças anuais nos scores ESG não se traduzem de forma imediata e sistemática nas métricas consideradas. Os benefícios das práticas ESG, reputação, redução de risco, eficiência operacional, confiança dos investidores, tendem a materializar-se gradualmente, o que os torna difíceis de detetar numa janela de cinco anos com modelos que exploram apenas variação intraempresa.

Em síntese, os modelos de efeitos fixos não identificam evidência robusta de que variações anuais nos scores ESG se traduzam em alterações significativas no Tobin's Q, ROA ou ROE. O único resultado parcialmente distinto corresponde à dimensão Governance no modelo de Tobin's Q, embora com sinal contrário ao esperado. Os resultados sugerem que, no período analisado, as alterações intraempresa nos indicadores ESG não produziram efeitos financeiros imediatamente observáveis através de especificações lineares com efeitos fixos.

4.2 Diagnósticos Econométricos

4.2.1 Multicolinearidade (VIF)

O Variance Inflation Factor (VIF) foi calculado para verificar se a correlação entre variáveis explicativas compromete a precisão dos coeficientes estimados. Os resultados, apresentados na Tabela 6, são tranquilizadores: todos os valores ficam muito abaixo do limiar de 5 habitualmente usado como referência.

Tabela 6 – Resultados do Variance Inflation Factor (VIF)

Variáveis	Modelo ESG	Modelo Pilares
ESG	1,149	—
Environmental	—	1,850
Social	—	1,666
Governance	—	1,088
InAssets	1,005	1,162
Leverage	1,017	1,048

Nota: Valores de VIF inferiores a 5 indicam ausência de multicolinearidade relevante.

Os pilares ESG apresentam os valores mais elevados, Environmental (1,85) e Social (1,67), o que é esperado dado que medem dimensões relacionadas. Ainda assim, estes níveis não levantam preocupações. As variáveis de controlo InAssets e Leverage estão próximas de 1 em ambas as especificações. Não há necessidade de recorrer a técnicas de correção como ortogonalização.

Os valores observados encontram-se substancialmente abaixo dos limiares de referência de 5 e 10 frequentemente utilizados na literatura (Wooldridge, 2020), indicando ausência de problemas relevantes de multicolinearidade e sugerindo que as estimativas dos coeficientes não se encontram artificialmente inflacionadas devido à correlação entre variáveis explicativas.

4.2.2 Testes de Diagnóstico dos Modelos em Painel

Para assegurar a validade dos resultados obtidos nos modelos econométricos, foram realizados diversos testes de diagnóstico, cujos resultados são apresentados na Tabela 7.

Tabela 7 – Resultados dos Testes de Diagnóstico dos Modelos em Painei

Teste	Estatística	p-value
Hausman (FE vs RE)	33,6173	0,000
Breusch-Pagan (resíduos FE)	172,9652	0
Autocorrelação tipo Wooldridge (aproximação)	4,9191	0
Jarque-Bera	18570,15	0

Os quatro testes realizados confirmam as opções metodológicas adotadas. O teste de Hausman rejeita os efeitos aleatórios ($\chi^2 = 33,62$; $p < 0,001$), validando a preferência pelos efeitos fixos, os efeitos individuais estão correlacionados com os regressores, o que tornaria o estimador RE inconsistente.

O teste de Breusch-Pagan deteta heterocedasticidade significativa ($LM = 172,97$; $p < 0,001$) e o teste tipo Wooldridge confirma autocorrelação serial dentro das empresas ($t = 4,92$; $p < 0,001$). Ambos os resultados justificam e validam a posteriori o uso de erros-padrão clusterizados por empresa, que são robustos a estes dois problemas em simultâneo.

Por fim, o Jarque-Bera rejeita a normalidade dos resíduos ($p < 0,01$). Em amostras grandes como esta, esta violação tem impacto limitado, embora a normalidade dos resíduos seja um pressuposto clássico do modelo linear, a sua violação tende a assumir menor relevância em amostras de grande dimensão. O Teorema do Limite Central garante que os estimadores se comportam assintoticamente bem e os erros-padrão robustos mitigam o problema residual.

Em conjunto, os diagnósticos econométricos fornecem suporte empírico para as opções metodológicas adotadas, nomeadamente a utilização de efeitos fixos e de erros-padrão clusterizados por empresa. Embora tenham sido identificadas heterocedasticidade, autocorrelação e não normalidade dos resíduos, estas limitações foram adequadamente mitigadas através da especificação adotada, permitindo interpretar os resultados obtidos com um grau elevado de confiança estatística.

4.2.3 Testes de Robustez

Com o objetivo de avaliar a robustez dos resultados obtidos nos modelos principais e mitigar potenciais preocupações associadas à multicolinearidade entre os pilares ESG, foram estimadas especificações alternativas.

Em particular, consideraram-se três abordagens complementares: (i) a inclusão de variáveis ESG defasadas (t-1), permitindo captar eventuais efeitos dinâmicos; (ii) a utilização dos pilares ESG defasados; e (iii) a estimação de modelos em que cada dimensão ESG, Environmental, Social e Governance é introduzida individualmente.

De forma geral, os resultados mantêm-se consistentes com os obtidos nos modelos principais. O coeficiente associado ao ESG defasado não é estatisticamente significativo, sugerindo que o desempenho ESG passado não exerce um impacto relevante na valorização de mercado no período subsequente. De igual forma, quando se consideram os pilares ESG defasados, nenhum dos coeficientes apresenta significância estatística, reforçando a ausência de evidência de efeitos dinâmicos relevantes no curto prazo. Os modelos com variáveis ESG defasadas foram igualmente estimados para o ROA e o ROE. Os resultados mantêm-se consistentes: nenhum coeficiente ESG lag atinge significância estatística em qualquer das três métricas financeiras, confirmando a ausência de efeitos dinâmicos de curto prazo independentemente da variável dependente considerada.

Tabela 8 – Resultados dos Modelos Alternativos (Testes de Robustez)

	(1) TobinQ ESG Lag	(2) TobinQ Pilares Lag	(3) ROA ESG Lag	(4) ROA Pilares Lag	(5) ROE ESG Lag	(6) ROE Pilares Lag	(7) TobinQ Environmental	(8) TobinQ Social	(9) TobinQ Governance
ESG_lag	-0,0002 (0,0029)	—	0,0001 (0,0002)	—	-0,0009 (0,0013)	—	—	—	—
Environmental_lag	—	-0,0062 (0,0051)	—	-0,0001 (0,0003)	—	-0,0004 (0,0013)	—	—	—
Social_lag	—	0,0047 (0,0048)	—	-0,0001 (0,0003)	—	0,0021 (0,0017)	—	—	—
Governance_lag	—	-0,0031 (0,0028)	—	0,0001 (0,0001)	—	0,0007 (0,0010)	—	—	—
Environmental	—	—	—	—	—	—	-0,0073 (0,0051)	—	—
Social	—	—	—	—	—	—	—	-0,0055 (0,0050)	—
Governance	—	—	—	—	—	—	—	—	-0,0056** (0,0027)
lnAssets	-0,9565** (0,4391)	-0,9491** (0,4459)	-0,0251 (0,0197)	-0,0243 (0,0204)	-0,1462* (0,0881)	-0,1445 (0,0916)	-1,1987*** (0,3702)	-1,2298*** (0,3704)	-1,2401*** (0,3655)
Leverage	-0,0880 (0,9126)	-0,1087 (0,9161)	-0,1746*** (0,0519)	-0,1736*** (0,0518)	0,3933 (0,4454)	0,4032 (0,4453)	0,0724 (0,7829)	0,0835 (0,7843)	0,1072 (0,7880)
Observações	1956	1956	1973	1973	1853	1853	2448	2448	2448
R ² within	0,0419	0,0463	0,0351	0,0361	0,014	0,0164	0,0791	0,0764	0,0794
FE Empresa	Sim	Sim	Sim	Sim	Sim	Sim	Sim	Sim	Sim
FE Ano	Sim	Sim	Sim	Sim	Sim	Sim	Sim	Sim	Sim

Nota: *** p < 0,01; ** p < 0,05; * p < 0,10. Erros-padrão entre parênteses.

A Tabela 8 apresenta os resultados destes modelos alternativos.

Nos modelos em que os pilares ESG são analisados individualmente, observa-se que apenas a dimensão de Governance apresenta um coeficiente negativo e estatisticamente significativo. No entanto, este resultado não se revela robusto entre diferentes especificações e níveis de significância, devendo, por isso, ser interpretado com cautela. As dimensões Environmental e Social não evidenciam efeitos estatisticamente significativos.

Por outro lado, a variável *LnAssets* mantém um coeficiente negativo e estatisticamente significativo em praticamente todas as especificações, confirmando a robustez do efeito do tamanho da empresa sobre o Tobin's Q. A variável *Leverage* continua a não apresentar um padrão consistente de significância estatística.

Importa analisar com maior detalhe o resultado obtido para a dimensão Governance no modelo (9) da Tabela 8, no qual o coeficiente surge negativo e estatisticamente significativo a 5% ($\beta = -0,0056$). Este resultado contraria parcialmente a hipótese H2 inicialmente formulada e sugere que, no curto prazo, práticas mais exigentes de governança corporativa podem estar associadas a custos adicionais para as empresas.

Em particular, scores mais elevados de Governance tendem a estar relacionados com maiores exigências de auditoria, criação de comitês independentes (como comitês de auditoria, remuneração ou sustentabilidade), implementação de mecanismos internos de controlo e aumento das obrigações de transparência e disclosure. Embora estas práticas possam contribuir para uma gestão mais robusta e para a redução do risco no longo prazo, os seus custos são imediatos e podem afetar temporariamente a valorização das empresas.

Adicionalmente, no contexto do S&P 500, composto por empresas já sujeitas a elevados níveis de supervisão e exigência regulatória, melhorias marginais nos scores de Governance poderão refletir sobretudo um reforço dos mecanismos de conformidade, sem necessariamente gerar ganhos proporcionais de eficiência ou criação de valor no curto prazo. Neste sentido, o mercado poderá interpretar estes investimentos mais como custos adicionais do que como benefícios imediatos, justificando o sinal negativo observado no período analisado.

Esta interpretação encontra suporte em estudos que defendem que os efeitos da governança corporativa sobre a valorização das empresas podem variar consoante o contexto institucional e o horizonte temporal considerado (Kim & Li, 2021), reforçando a importância de analisar não apenas os potenciais benefícios das práticas ESG, mas também os custos associados à sua implementação.

Estes resultados reforçam as conclusões principais do estudo, indicando que a ausência de relação estatisticamente significativa entre o desempenho ESG e a valorização de mercado não

depende da especificação do modelo adotado.

Em síntese, nenhuma das especificações alternativas, variáveis defasadas para Tobin's Q, ROA e ROE, ou pilares analisados individualmente, altera a conclusão principal: o desempenho ESG não apresenta um efeito linear estatisticamente significativo sobre as métricas financeiras consideradas, sendo os resultados robustos a potenciais problemas de multicolinearidade e à consideração de efeitos dinâmicos de curto prazo.

4.3 Resultados da Modelação Preditiva (Random Forest)

Para cada variável dependente: Tobin's Q, ROA e ROE, foram estimados dois modelos: um com o ESG Combined Score e outro com os três pilares separadamente. Esta separação é intencional: evita que o score agregado e os pilares partilhem variância explicada, o que distorceria a comparação entre as duas conceptualizações. Ambos incluem também o Controversies Score, enquanto InAssets e Leverage entram como variáveis de controlo. Adicionalmente, para cada variável dependente estimou-se um modelo apenas com os controlos (InAssets e Leverage), de forma a quantificar o contributo incremental da informação ESG (ΔR^2), bem como um modelo linear (OLS) com exatamente as mesmas variáveis, para isolar o papel das relações não lineares. Os hiperparâmetros foram ajustados via GridSearchCV com validação cruzada de 5 folds, e o desempenho foi avaliado com duas estratégias: divisão aleatória 80/20 e divisão temporal estrita (treino: 2019–2022; teste: 2023).

Tabela 9 – Desempenho Preditivo dos Modelos Random Forest (Out-of-Sample)

PAINEL A — Random Split (80/20)										
Label	Target	Features	Split	N_test	RMSE	MAE	R ² (só controlos)	R ² (completo)	ΔR^2 (ESG)	Baseline_R2
TobinQ_Agg	TobinQ	Agg	Random	490	1,6657	1,1095	0,4493	0,4945	0,0452	-0,003
TobinQ_Pil	TobinQ	Pil	Random	490	1,5757	1,0351	0,4437	0,5476	0,1039	-0,003
ROA_Agg	ROA	Agg	Random	495	0,06	0,0415	0,2398	0,3203	0,0805	-0,0044
ROA_Pil	ROA	Pil	Random	495	0,0579	0,0397	0,2216	0,367	0,1454	-0,0044
ROE_Agg	ROE	Agg	Random	467	0,6108	0,2791	0,1358	0,1668	0,031	-0,0049
ROE_Pil	ROE	Pil	Random	467	0,5809	0,2654	0,0917	0,246	0,1543	-0,0049
PAINEL B — Time-Based Split (treino: 2019–2022; teste: 2023)										
TobinQ_Agg_Time	TobinQ	Agg	TimeBased	492	1,8371	1,2366	—	0,4432	—	0
TobinQ_Pil_Time	TobinQ	Pil	TimeBased	492	1,7637	1,1836	—	0,4868	—	0
ROA_Agg_Time	ROA	Agg	TimeBased	501	0,065	0,0461	—	0,1984	—	-0,0022
ROA_Pil_Time	ROA	Pil	TimeBased	501	0,0608	0,0425	—	0,2987	—	-0,0022
ROE_Agg_Time	ROE	Agg	TimeBased	471	0,4993	0,2422	—	0,1013	—	0
ROE_Pil_Time	ROE	Pil	TimeBased	471	0,4648	0,2238	—	0,2213	—	0

Nota: Hiperparâmetros ajustados via GridSearchCV (5-fold) sobre o conjunto de treino. "Agg" inclui o ESG Combined Score; "Pil" inclui os três pilares (E, S, G) separadamente; ambos incluem também o Controversies Score. InAssets e Leverage entram como variáveis de controlo em todos os modelos. R² (só controlos) refere-se ao modelo apenas com InAssets e Leverage; ΔR^2 (ESG) = R² (completo) – R² (só controlos), medindo o contributo incremental da informação ESG na mesma amostra e divisão treino-teste (apenas Painel A). Baseline_R2 corresponde a um modelo ingénuo (média). Métricas out-of-sample no conjunto de teste.

Os resultados são claros: ambos os modelos superam largamente o baseline em todas as variáveis dependentes. Para o Tobin's Q, o modelo desagregado alcança um R^2 out-of-sample de 0,548 contrastando com um baseline de -0,003. O modelo agregado (0,494) também supera o baseline, mas fica aquém do desagregado, o que sugere que agregar os pilares num único score implica perda de informação útil.

Para o ROA, o modelo desagregado obtém R^2 de 0,367 face a 0,320 no agregado, capacidade preditiva moderada, mas consistente com o padrão observado no Tobin's Q. O ROE é o target mais difícil, com R^2 de 0,246 no modelo desagregado e 0,167 no agregado, mas mesmo aqui a vantagem da desagregação (+8,0 pontos percentuais) e a melhoria face ao baseline são consistentes.

A divisão temporal confirma a robustez: treinar em 2019–2022 e testar em 2023 reduz o desempenho entre 3 e 7 pontos percentuais consoante o target, mas os modelos mantêm capacidade preditiva substancialmente acima do baseline em todas as configurações. A vantagem do modelo desagregado mantém-se em todos os casos. O sinal nas variáveis ESG é genuíno, não é um artefacto da divisão dos dados.

Para quantificar especificamente o contributo da informação ESG, comparou-se o R^2 out-of-sample de cada modelo com o de um modelo equivalente contendo apenas os controlos (LnAssets e Leverage), na mesma amostra e divisão treino-teste. O contributo incremental (ΔR^2) é relevante nos modelos desagregados: o R^2 aumenta de 0,444 para 0,548 no Tobin's Q ($\Delta R^2 = 0,104$), de 0,222 para 0,367 no ROA ($\Delta R^2 = 0,145$) e de 0,092 para 0,246 no ROE ($\Delta R^2 = 0,154$). Nos modelos com o score agregado o contributo é positivo, mas mais modesto (ΔR^2 entre 0,031 e 0,080), reforçando que os pilares individuais transportam informação que o score combinado dilui. Por outras palavras, depois de descontar a dimensão e o endividamento, a informação ESG continua a explicar entre 10 e 15 pontos percentuais da variação out-of-sample nos modelos por pilares.

Para isolar o papel da não-linearidade, estimou-se ainda um modelo linear (OLS) com exatamente as mesmas variáveis do Random Forest. Em todas as especificações o Random Forest supera claramente o OLS na previsão fora da amostra; no Tobin's Q desagregado, por exemplo, o R^2 passa de 0,281 (OLS) para 0,548 (Random Forest). Como ambos partilham as mesmas variáveis e a mesma amostra, esta diferença não decorre do conjunto de informação utilizado, mas da capacidade do Random Forest para captar relações não lineares e interações entre as variáveis, o que constitui evidência direta a favor de H3.

Importa, ainda assim, sublinhar que estes resultados são de natureza preditiva (*out-of-sample*) e não causal, sendo compatíveis com a ausência de uma associação linear significativa nos modelos de painel com efeitos fixos: a relação entre o ESG e o desempenho financeiro

manifesta-se sobretudo de forma não linear e dependente do contexto, e não através de um efeito linear médio.




Figura 1 – Permutation Importance no Random Forest (Tobin's Q, modelo desagregado por pilares)

Nota: Importância calculada via permutação no conjunto de teste, com 30 repetições. Barras de erro indicam o desvio-padrão entre permutações.




Figura 2 – Permutation Importance no Random Forest (Tobin's Q, modelo agregado)

Nota: Importância calculada via permutação no conjunto de teste, com 30 repetições. Barras de erro indicam o desvio-padrão entre permutações.

A permutation importance, métrica mais robusta do que a Mean Decrease Impurity por ser invariante à cardinalidade das variáveis revela um padrão consistente: InAssets é de longe o principal determinante preditivo em todos os modelos, seguido de Leverage. Entre as variáveis ESG, o pilar Social é o mais informativo para o Tobin's Q (0,096) e para o ROE (0,088), enquanto o Environmental lidera no ROA (0,122). A Governance surge como o pilar menos informativo no ROA e no ROE; no Tobin's Q, porém, é o Environmental que registra a menor importância. Este padrão refletirá sobretudo a reduzida variabilidade destas dimensões entre as empresas do S&P 500.

Um resultado particularmente relevante: em todos os targets, o pilar ESG mais informativo supera o ESG Combined Score isolado. A desagregação não é apenas uma opção metodológica, é empiricamente preferível. Importa notar que a permutation importance é específica de cada modelo, uma vez que é calculada sobre conjuntos de variáveis distintos; a comparação direta da magnitude da importância do pilar mais informativo (modelo desagregado) com a do ESG Combined Score (modelo agregado) deve, por isso, ser entendida como indicativa. Esta conclusão é, no entanto, sustentada de forma independente pelo ganho de R^2 *out-of-sample* do modelo desagregado face ao agregado, observado em todos os alvos e em ambas as estratégias de divisão, o que reforça a sua robustez.

Tabela 10 – Permutation Importance (consolidada)

Variável	TobinQ (Agg)	TobinQ (Pil)	ROA (Agg)	ROA (Pil)	ROE (Agg)	ROE (Pil)
ESG	0,059 ± 0,013	—	0,088 ± 0,016	—	0,037 ± 0,008	—
Environmental	—	0,046 ± 0,010	—	0,122 ± 0,017	—	0,062 ± 0,014
Social	—	0,096 ± 0,015	—	0,080 ± 0,011	—	0,088 ± 0,019
Governance	—	0,057 ± 0,011	—	0,051 ± 0,008	—	0,037 ± 0,011
Controversies	0,048 ± 0,013	0,044 ± 0,011	0,077 ± 0,009	0,066 ± 0,011	0,016 ± 0,008	0,016 ± 0,012
InAssets	0,784 ± 0,072	0,864 ± 0,065	0,626 ± 0,046	0,718 ± 0,053	0,119 ± 0,040	0,186 ± 0,043
Leverage	0,223 ± 0,030	0,180 ± 0,019	0,180 ± 0,017	0,138 ± 0,015	0,197 ± 0,027	0,294 ± 0,040




Figura 3 – Partial Dependence Plots: Tobin's Q vs Pilares ESG (modelo Random Forest desagregado)

Os PDPs mostram que a relação entre os pilares ESG e o Tobin's Q não é monótona e cada pilar conta uma história diferente. No pilar Social, observa-se um efeito crescente até scores intermédios, seguido de um plateau ou ligeira inflexão em valores elevados. Padrão semelhante nos restantes pilares. Os resultados fornecem suporte empírico para H3. Enquanto os modelos lineares com efeitos fixos não identificaram relações estatisticamente significativas entre ESG e desempenho financeiro, os modelos Random Forest alcançaram níveis substanciais de capacidade preditiva e evidenciaram padrões não lineares nos Partial Dependence Plots. Esta divergência sugere que parte da informação contida nas métricas ESG se manifesta através de relações complexas que não são adequadamente representadas por especificações lineares tradicionais. Os Partial Dependence Plots devem, ainda assim, ser interpretados com a ressalva habitual de que assumem independência entre variáveis; dada a correlação moderada entre os pilares Environmental e Social (cf. Tabela 4), parte do domínio representado corresponde a combinações menos frequentes na amostra.

No pilar Social observa-se um aumento mais pronunciado do Tobin's Q esperado para valores superiores a aproximadamente 70 pontos, sugerindo a existência de um possível efeito de limiar. Melhorias marginais em empresas já bem posicionadas socialmente parecem gerar benefícios de valorização superiores aos observados em empresas com scores médios ou baixos.

O pilar Environmental apresenta igualmente um comportamento não linear, com um aumento acentuado da valorização prevista após determinado nível de desempenho ambiental, sugerindo que os investidores podem atribuir maior relevância a empresas que ultrapassam determinados padrões mínimos nesta dimensão.

O PDP da dimensão Governance apresenta uma tendência globalmente descendente, consistente com o coeficiente negativo observado nos modelos econométricos. Este resultado sugere que, no contexto das empresas do S&P 500, níveis mais elevados de governance podem estar associados a maiores custos de conformidade e reporte, cuja materialização no curto prazo poderá superar os benefícios económicos esperados.

Apesar da relevância das variáveis ESG, os resultados demonstram que as características financeiras tradicionais continuam a desempenhar um papel dominante na explicação do desempenho empresarial. Em particular, a variável $\ln\text{Assets}$ apresenta níveis de importância significativamente superiores aos restantes preditores em todos os modelos, sugerindo que a dimensão da empresa continua a ser o principal determinante do desempenho financeiro e da valorização de mercado.

Importa, contudo, interpretar o papel do $\ln\text{Assets}$ com alguma cautela. Tanto o Tobin's Q ($\text{Market Cap} / \text{Total Assets}$) como o ROA ($\text{Resultado Líquido} / \text{Total Assets}$) incorporam o total de

ativos na sua construção, enquanto o *InAssets* corresponde precisamente ao logaritmo dessa mesma variável. Consequentemente, existe uma relação estrutural entre este preditor e estas métricas de desempenho, o que significa que parte da sua elevada importância preditiva poderá resultar da própria construção das variáveis e não apenas de um efeito económico associado à dimensão da empresa.

Esta interpretação encontra suporte nos resultados obtidos. Enquanto a importância do *InAssets* é particularmente elevada nos modelos de Tobin's Q (0,784–0,864) e ROA (0,626–0,718), diminui de forma substancial nos modelos de ROE (0,119–0,186), uma métrica que não utiliza o total de ativos no seu cálculo. Este padrão sugere que uma parte da relevância atribuída ao *InAssets* decorre da proximidade conceptual e matemática entre esta variável e os indicadores de desempenho considerados.

Ainda assim, a dimensão da empresa continua a revelar-se um fator relevante na explicação do desempenho financeiro. Os resultados devem, porém, ser interpretados tendo em consideração esta limitação metodológica, sobretudo no caso do Tobin's Q e do ROA. Importa igualmente salientar que as principais conclusões do estudo permanecem inalteradas: a superioridade da especificação desagregada por pilares ESG e a evidência de relações não lineares mantêm-se consistentes, independentemente do contributo específico do *InAssets* para a capacidade preditiva dos modelos.

Em síntese, os resultados preditivos apontam em três direções consistentes: as métricas ESG contêm informação preditiva relevante; a desagregação por pilares é sistematicamente superior à agregação; e a existência de relações não lineares nos PDPs fornece suporte empírico para H3, justificando a complementaridade entre econometria e Machine Learning.

4.4 Integração dos Resultados Económétricos e Preditivos

Os modelos económétricos e o Random Forest contam histórias diferentes sobre o mesmo fenómeno e a tensão entre elas é, em si mesma, informativa.

Os modelos FE não encontram relações estatisticamente significativas entre ESG e desempenho financeiro em nenhuma especificação. O Random Forest, por sua vez, alcança R^2 out-of-sample de 0,548 para o Tobin's Q e 0,367 para o ROA, capacidade preditiva real substancialmente acima do baseline. Esta divergência não constitui uma contradição, mas exige cuidado interpretativo, pois as duas abordagens diferem em dois aspetos simultâneos. Por um lado, os modelos de efeitos fixos eliminam por construção a variação *between-firm*, identificando os coeficientes apenas a partir da variação intraempresa que, como mostra a Tabela 11, é reduzida.

Por outro, o Random Forest é estimado sem efeitos fixos de empresa, explorando também a variação transversal, além de admitir relações não lineares e interações. Para separar estes dois efeitos, estimou-se um modelo linear (OLS) com exatamente as mesmas variáveis e a mesma amostra do Random Forest, igualmente sem efeitos fixos: este OLS explora a mesma variação *between-firm* que o Random Forest, isolando assim o papel da forma funcional. Os resultados mostram que o Random Forest supera claramente o OLS (no Tobin's Q desagregado, R^2 de 0,55 contra 0,28), o que indica que o seu desempenho superior não decorre apenas de aproveitar variação descartada pelos efeitos fixos, mas reflete genuinamente relações não lineares e interações entre as variáveis. A forma não monótona dos *Partial Dependence Plots* (Figura 3) corrobora esta leitura.

Uma parte da explicação está na estrutura dos dados. A Tabela 11 mostra que a variação intraempresa dos scores ESG é limitada: o desvio-padrão within representa apenas 52% da variação total para o ESG agregado, e apenas 26% e 30%, para os pilares Environmental e Social, respetivamente, calculado como o rácio entre o desvio-padrão within médio por empresa e o desvio-padrão total da amostra (cf. Tabela 11). Em alguns casos observa-se mesmo ausência total de variação intraempresa nos pilares Environmental e Governance, o que reduz substancialmente a informação disponível para identificação dos coeficientes nos modelos de efeitos fixos. Quando o estimador opera com tão pouco sinal, a ausência de significância estatística pode refletir limitações da estrutura dos dados tanto quanto ausência de relação económica.

Tabela 11 – Variação intraempresa (within-firm) dos scores ESG (2019-2023)

	ESG	Environmental	Social	Governance
count	500	500	500	500
mean	8,012	5,69	4,989	8,587
std	4,921	4,998	3,441	4,845
min	0,558	0	0,322	0
25%	3,828	2,442	2,556	5,156
50%	6,648	4,151	4,191	7,611
75%	12,496	7,445	6,597	11,062
max	23,26	27,956	24,829	27,506
Std Total (referência)	15,348	21,918	16,789	19,387

A distinção entre inferência causal e capacidade preditiva é fundamental para interpretar estes resultados corretamente. Os modelos FE são conservadores por design, exploram apenas variação intraempresa e assumem relações lineares. O Random Forest é mais flexível: capta relações não lineares, interações entre variáveis e padrões que os modelos lineares ignoram. Os PDPs mostram isso concretamente: a relação entre ESG e Tobin's Q não é monótona, e há evidência de efeitos de limiar no pilar Social que nenhuma especificação linear conseguiria

detetar.

Há ainda dois padrões que merecem nota. Primeiro, a desagregação por pilares melhora consistentemente o desempenho preditivo em todos os targets, o que significa que o score agregado esconde informação que os pilares individuais preservam. Segundo, o Tobin's Q é sistematicamente mais sensível ao ESG do que o ROA ou o ROE, consistente com a ideia de que os investidores incorporam fatores ESG nas suas expectativas de longo prazo antes de esses fatores se materializarem nos resultados contabilísticos.

A análise setorial da secção seguinte acrescenta uma última peça: efeitos ESG estatisticamente significativos existem, mas em direções opostas entre setores. O efeito médio nulo nos modelos agregados resulta, em parte, da compensação entre um efeito positivo em Industriais e um efeito negativo em Real Estate. Uma leitura puramente agregada esconderia esta heterogeneidade.

4.5 Análise de Heterogeneidade Setorial

A análise agregada dos modelos FE mostrou ausência de efeito médio do ESG sobre o desempenho financeiro. Esta secção questiona se esse resultado médio esconde dinâmicas opostas entre setores e a resposta é sim.

Os modelos foram estimados separadamente para os principais macro setores, mapeados a partir das classificações TRBC e compatibilizados com a nomenclatura GICS. Foram retidos apenas os setores com dimensão suficiente para garantir um nível mínimo de robustez estatística. Os setores com reduzido número de observações foram agregados numa categoria residual designada por "Other". A Tabela 12 apresenta, assim, oito macro setores analisados individualmente, acrescidos desta categoria residual.

Tabela 12 – Heterogeneidade Setorial: Tobin's Q - ESG por Setor

Setor	Model	N	ESG	Environmental	Social	Governance	InAssets	Leverage	R2_within
Consumer Discretionary	Agg	160	0,0034 (0,0065)	—	—	—	-1,5438 (1,4120)	1,8351* (0,9272)	0,0126
Consumer Discretionary	Pil	160	—	-0,0100 (0,0141)	-0,0138 (0,0130)	-0,0071 (0,0074)	-1,0963 (1,1766)	1,2528 (0,9429)	0,0522
Consumer Staples	Agg	150	0,0023 (0,0025)	—	—	—	-0,8125* (0,4833)	-2,2214 (2,5276)	0,1152
Consumer Staples	Pil	150	—	-0,0056 (0,0083)	-0,0078 (0,0081)	-0,0024 (0,0031)	-0,8756* (0,4751)	-2,5606 (2,5093)	0,1181
Financials	Agg	255	0,0007 (0,0014)	—	—	—	-0,1335* (0,0753)	-0,0848 (0,8911)	-0,0063
Financials	Pil	255	—	-0,0026 (0,0046)	0,0051 (0,0045)	0,0014 (0,0012)	-0,1290 (0,0840)	-0,0897 (0,8924)	0,0072
Health Care	Agg	218	-0,0044 (0,0045)	—	—	—	-1,2739** (0,5797)	2,8691 (2,0111)	0,0794
Health Care	Pil	218	—	-0,0285* (0,0165)	-0,0137 (0,0173)	-0,0032 (0,0109)	-1,1516* (0,6055)	2,8318 (2,1064)	0,1303
Industrials	Agg	270	0,0189** (0,0078)	—	—	—	-1,6980 (1,4989)	-0,4133 (1,9248)	0,0496
Industrials	Pil	270	—	0,0034 (0,0116)	0,0108 (0,0129)	-0,0019 (0,0057)	-1,6932 (1,4749)	-0,5868 (2,0578)	0,0587
Information Technology	Agg	485	0,0060 (0,0082)	—	—	—	-2,3251** (0,9011)	2,7748 (2,0366)	0,1494
Information Technology	Pil	485	—	-0,0081 (0,0127)	0,0065 (0,0144)	-0,0109 (0,0086)	-2,2755** (0,9060)	2,6930 (2,0273)	0,1642
Other	Agg	317	0,0019 (0,0062)	—	—	—	-1,2960* (0,6690)	-2,6327 (1,9438)	0,0836
Other	Pil	317	—	-0,0040 (0,0106)	-0,0147 (0,0110)	-0,0019 (0,0096)	-1,2818* (0,6953)	-2,5084 (2,0214)	0,09
Real Estate	Agg	149	-0,0102* (0,0057)	—	—	—	-0,3814 (0,2666)	-0,0015 (1,2048)	0,1182
Real Estate	Pil	149	—	-0,0130** (0,0060)	0,0105 (0,0064)	-0,0042 (0,0041)	-0,3500 (0,2612)	0,1800 (1,0695)	0,1798
Utilities	Agg	145	0,0018 (0,0019)	—	—	—	-0,2570 (0,3296)	1,7567* (0,9712)	0,2099
Utilities	Pil	145	—	-0,0014 (0,0018)	0,0011 (0,0016)	-0,0005 (0,0012)	-0,2020 (0,3592)	1,8246* (1,0006)	0,2132

Nota: Coeficientes do modelo de painel com efeitos fixos de empresa e de ano, estimados separadamente para cada setor.

Erros-padrão clusterizados por empresa omitidos por questão de espaço (disponíveis no Anexo). Inclui-se controlo para InAssets e Leverage. ***p<0,01; **p<0,05; *p<0,10. R²w = R² within.

O setor Industrials é o único onde o ESG agregado apresenta um efeito positivo e estatisticamente significativo a 5% ($\beta = 0,0189$). No modelo desagregado, nenhum pilar individual atinge significância, o que sugere que é o desempenho ESG global, e não uma dimensão específica, que o mercado valoriza neste setor. Uma interpretação plausível: em indústrias com maior exposição a riscos ambientais e sociais, um perfil ESG robusto funciona como sinal de gestão de risco, sendo incorporado nas expectativas de valorização.

O Real Estate apresenta o padrão oposto: coeficiente negativo e significativo a 10% no modelo agregado ($\beta = -0,0102$), e negativo e significativo a 5% no pilar Environmental ($\beta =$

-0,0130) no modelo desagregado. Este resultado pode refletir o facto de melhorias ambientais neste setor (certificações energéticas, retrofits e requisitos de sustentabilidade) envolverem custos de capital elevados que o mercado penaliza no curto prazo, antes de os benefícios se materializarem.

O Health Care segue uma lógica semelhante: coeficiente negativo no modelo agregado (não significativo) e negativo e marginalmente significativo a 10% no pilar Environmental ($\beta = -0,0285$). Setores intensivamente regulados como saúde podem ver as melhorias ESG como custos adicionais de conformidade, com impacto imediato na valorização.

Nos restantes setores, Consumer Discretionary, Consumer Staples, Financials, Information Technology e Utilities, nenhum coeficiente ESG atinge significância estatística, o que é consistente com os resultados dos modelos globais. Importa referir que a categoria "Other" agrega setores com características distintas e reduzida representação individual, pelo que os respetivos coeficientes devem ser interpretados com cautela. Esta categoria é incluída sobretudo por razões de completude e para preservar a dimensão total da amostra. Dado o número de setores e especificações estimadas, os resultados setoriais devem ser interpretados como exploratórios: alguns coeficientes marginalmente significativos podem decorrer de comparações múltiplas, e as subamostras de menor dimensão (e.g., Real Estate, Consumer Staples) oferecem poder estatístico limitado.

O efeito médio nulo observado nos modelos agregados não significa que o ESG seja irrelevante, significa que efeitos de sinal oposto entre setores se compensam mutuamente. Industrials e Real Estate são o exemplo mais claro: um efeito positivo e um negativo que, agregados, tendem para zero. Esta heterogeneidade estrutural justifica abordagens segmentadas e reforça a conclusão de que o impacto do ESG depende fortemente do contexto setorial em que opera.

5 Conclusão

5.1 Síntese dos principais resultados

Esta dissertação partiu de uma questão simples, mas empiricamente difícil: será que empresas que melhoram o seu desempenho ESG melhoram também o seu desempenho financeiro? A resposta, como frequentemente acontece quando os dados são tratados com rigor, é inconclusiva, mas de uma forma que conta uma história interessante.

Os modelos econométricos com efeitos fixos não encontram evidência estatisticamente significativa de que variações anuais nos scores ESG se traduzam em variações no Tobin's Q, no ROA ou no ROE. Este resultado é estável: mantém-se com variáveis defasadas, com os pilares analisados individualmente e em diferentes especificações. A única exceção parcial é o pilar de Governança, que num dos modelos alternativos apresenta um coeficiente negativo marginalmente significativo, resultado que, pela sua inconsistência entre especificações, não altera a conclusão geral.

Parte da explicação está na estrutura dos dados. A variação intraempresa dos scores ESG é limitada, representa apenas 26% a 52% da variação total dependendo do pilar, e há empresas com scores constantes ao longo de todo o período. Quando o estimador opera com tão pouco sinal, a ausência de significância pode refletir limitações dos dados tanto quanto ausência de relação económica.

Os modelos de Random Forest contam uma história diferente. Com R^2 *out-of-sample* de 0,55 para o Tobin's Q e 0,37 para o ROA, as variáveis ESG demonstram capacidade preditiva real e, sobretudo, um contributo incremental de 10 a 15 pontos percentuais face a um modelo apenas com controlos (lnAssets e Leverage) nas especificações por pilares, o que confirma que o sinal ESG não se reduz ao efeito da dimensão da empresa. Essa capacidade é consistentemente maior quando os pilares são analisados separadamente, o score agregado dilui informação que os pilares individuais preservam. Os Partial Dependence Plots confirmam relações não lineares que especificações lineares simplesmente não captam: efeitos de limiar no pilar Social, comportamento não monótono no Environmental, e uma tendência descendente na Governance consistente com os custos de conformidade observados nos modelos FE.

A análise setorial acrescenta uma dimensão importante. O efeito médio nulo esconde dinâmicas opostas: Industriais apresenta um efeito positivo e significativo e o Real Estate um efeito negativo (significativo no pilar Environmental), enquanto o Health Care exhibe um efeito negativo apenas marginalmente significativo nessa dimensão. Agregar estes setores produz um zero que não existe em lado nenhum.

Relativamente às hipóteses: H1 não é suportada. Os modelos de efeitos fixos não identificam uma associação linear positiva entre o ESG e o desempenho financeiro, e a análise setorial revela mesmo efeitos de sinal oposto entre indústrias, incompatíveis com uma associação positiva generalizada. O valor informativo das métricas ESG manifesta-se, antes, através de relações não lineares e dependentes do contexto setorial, evidência que se enquadra em H3 e não em H1. H2 é parcialmente suportada, mas com uma inversão, é o pilar Social, e não a Governance que emerge como o mais informativo para o Tobin's Q e o ROE; a Governance apresenta a menor importância relativa no ROA e no ROE, possivelmente por ser a dimensão com menor variabilidade entre as empresas do S&P 500. H3 é confirmada: o Random Forest supera as especificações lineares, no Tobin's Q desagregado, o R^2 *out-of-sample* passa de 0,28 (OLS, mesmas variáveis) para 0,55 e os PDPs evidenciam as não-linearidades previstas.

5.2 Contributos teóricos e metodológicos

O principal contributo deste trabalho não reside em nenhuma das duas abordagens isoladamente, mas na tensão entre elas. Essa tensão permite extrair três conclusões com relevância para a literatura. A primeira é que a agregação dos pilares num único score dilui informação. Esta dissertação fornece evidência empírica direta para uma crítica que a literatura mais recente vinha formulando sobretudo a nível conceptual (Shakil, 2024; Zhang & Hao, 2024): em todos os alvos considerados, a especificação desagregada por pilares supera sistematicamente o ESG Combined Score. O resultado tem uma implicação clara, tratar E, S e G como um bloco homogéneo não é apenas uma simplificação teórica discutível, é uma perda mensurável de capacidade explicativa. A segunda é que a divergência entre inferência e previsão é, em si mesma, um resultado, e não uma contradição. Os modelos de efeitos fixos respondem a uma pergunta causal e conservadora, se uma empresa altera o seu ESG, isso move o seu desempenho financeiro? enquanto o Random Forest responde a uma pergunta preditiva, as variáveis ESG contêm informação útil? As duas respostas, "não de forma sistemática" e "sim", coexistem sem incoerência. Isto sugere que parte da literatura que se apoia exclusivamente em especificações lineares poderá estar a subestimar de forma sistemática o conteúdo informativo das métricas ESG, simplesmente porque a sua relação com o desempenho é não linear e dependente de interações.

A terceira é que a heterogeneidade setorial é estrutural, não ruído. A constatação de que efeitos de sinal oposto se compensam até um efeito médio nulo confirma, com dados do S&P 500, o que revisões abrangentes da literatura vinham apontando (Gillan et al., 2021; Brooks & Oikonomou, 2018): a ausência de padronização e a dependência do contexto setorial continuam a dificultar a deteção de efeitos economicamente significativos quando a análise é puramente

agregada.

5.3 Implicações práticas

Para os investidores e analistas, o resultado mais acionável é que a informação ao nível dos pilares é preferível ao score compósito, e que a relação com a valorização é não linear e sensível ao setor. A existência de um possível efeito de limiar no pilar Social, em que melhorias acima de determinado nível parecem gerar ganhos de valorização superiores, sugere que a incorporação de critérios ESG em estratégias de investimento beneficia de uma leitura desagregada e atenta ao contexto setorial, em detrimento de filtros baseados num único número.

Para os gestores, a evidência de que melhorias na dimensão de Governança podem associar-se a custos de conformidade de curto prazo, num universo de empresas já fortemente reguladas como o S&P 500, é um alerta útil: o retorno das práticas ESG tende a materializar-se de forma gradual, e a sua avaliação não deve assentar em horizontes demasiado curtos.

Para os fornecedores de dados e agências de notação, o facto de a agregação destruir informação preditiva constitui um argumento empírico a favor de uma maior transparência e disponibilização ao nível dos pilares. Para os reguladores, a persistência de problemas de comparabilidade e de qualidade desigual da divulgação reforça a relevância dos esforços de padronização do reporte de sustentabilidade, condição para que os scores meçam mudança real e não apenas comprometimento formal.

5.4 Limitações

Várias limitações qualificam estas conclusões. A janela temporal de cinco anos é curta para captar efeitos estruturais de longo prazo, e inclui o período pandémico, um choque exógeno que distorce a relação entre ESG e desempenho. A reduzida variação intraempresa dos scores ESG limita o poder estatístico dos modelos de efeitos fixos. As subamostras setoriais têm dimensões variáveis, o que pode afetar a deteção de efeitos em setores menos representados.

Uma limitação relativa à construção da amostra. Por se ter partido da composição do índice num momento único, projetada retrospectivamente para todo o período, a análise está sujeita a um potencial viés de sobrevivência: ficam excluídas as empresas que integraram o S&P 500 durante o período, mas que dele saíram antes do final (por desempenho, aquisição ou exclusão). Esta seleção tende a enviesar a amostra no sentido de empresas mais estáveis e bem-sucedidas, podendo subestimar a variabilidade do desempenho e atenuar eventuais associações com os fatores ESG. Investigação futura beneficiaria da utilização da composição histórica completa do índice, ano a ano, para mitigar este efeito.

Acrescem duas limitações de natureza construtiva. O Tobin's Q foi aproximado por uma

medida simplificada de valor de mercado sobre ativos, que não incorpora a dívida no numerador; e, dado que

o Tobin's Q e o ROA são escalados pelo total de ativos, o protagonismo do *LnAssets* nos modelos preditivos reflete, em parte, essa ligação mecânica, pelo que a magnitude do R^2 destes dois alvos deve ser lida com prudência, note-se que a importância do *LnAssets* cai precisamente no ROE, métrica que não partilha o denominador. As conclusões substantivas do estudo, contudo, a superioridade da desagregação e a presença de não-linearidades, não dependem deste preditor. Por fim, a abordagem preditiva, embora eficaz na identificação de padrões, não permite estabelecer relações causais.

Do ponto de vista metodológico, o trabalho oferece um modelo replicável de articulação entre econometria explicativa e Machine Learning preditivo, em que a *permutation importance* e os *Partial Dependence Plots* funcionam como instrumentos de diagnóstico do sinal ESG. Esta combinação não substitui nenhuma das abordagens; expõe, antes, aquilo que cada uma isoladamente não consegue ver.

5.5 Sugestões para investigação futura

Várias direções parecem promissoras. Alargar o horizonte temporal permitiria captar efeitos graduais e reduzir a influência de choques macroeconómicos como o da pandemia, idealmente complementado por especificações que excluam o período mais perturbado. Tratar formalmente a endogeneidade com variáveis instrumentais ou modelos GMM fortaleceria as conclusões causais. Controlar a qualidade da divulgação, à semelhança de Fatemi et al. (2018), permitiria separar o sinal ESG do ruído introduzido por práticas de reporte desiguais.

Particularmente promissora é a aplicação de métodos de Machine Learning causal, como *causal forests* ou *double Machine Learning*, que procuram precisamente unir a flexibilidade preditiva à identificação de efeitos causais, atenuando a fronteira que, nesta dissertação, separou as duas abordagens. A análise da dinâmica das controvérsias ESG e a extensão a outros mercados e geografias completariam o quadro. Em última análise, aplicar modelos híbridos que integrem a capacidade inferencial da econometria com a flexibilidade preditiva do Machine Learning poderia oferecer uma leitura mais completa de um fenómeno que, como esta dissertação procurou mostrar, não cabe em nenhuma das duas abordagens isoladamente.

6 Referências Bibliográficas

- Agbakwuru, V., Onyenahazi, O. B., Antwi, B. O., & Oyewale, K. (2024). The impact of Environmental, Social, and Governance (ESG) reporting on corporate financial performance. *International Journal of Research Publication and Reviews*, 5(9), 3629–3644. <https://doi.org/10.55248/gengpi.5.0924.2710>
- Alareeni, B. A., & Hamdan, A. (2020). ESG impact on performance of US S&P 500-listed firms. *Corporate Governance: The International Journal of Business in Society*, 20(7), 1409–1428. <https://doi.org/10.1108/CG-06-2020-0258>
- Alfalih, A. A. (2023). ESG disclosure practices and financial performance: A general and sector analysis of S&P 500 non-financial companies and the moderating effect of economic conditions. *Journal of Sustainable Finance & Investment*, 13(4), 1506–1533. <https://doi.org/10.1080/20430795.2022.2150511>
- Broadstock, D. C., Chan, K., Cheng, L. T. W., & Wang, X. (2021). The role of ESG performance during times of financial crisis: Evidence from COVID-19 in China. *Finance Research Letters*, 38, 101716. <https://doi.org/10.1016/j.frl.2020.101716>
- Brooks, C., & Oikonomou, I. (2018). The effects of environmental, social and governance disclosures and performance on firm value: A review of the literature in accounting and finance. *The British Accounting Review*, 50(1), 1–15. <https://doi.org/10.1016/j.bar.2017.11.005>
- Bustillo-Castillejo, M. C., Pérez-Morote, R., & González-Moreno, Á. (2023). Corporate social responsibility and community legitimacy: Colombian Caribbean insights. *Sustainability*, 15(18), 13659. <https://doi.org/10.3390/su151813659>
- Chung, K. H., & Pruitt, S. W. (1994). A simple approximation of Tobin's q. *Financial Management*, 23(3), 70–74. <https://doi.org/10.2307/3665623>
- Cohen, G. (2023). ESG risks and corporate survival. *Environment Systems and Decisions*, 43(1), 16–21. <https://doi.org/10.1007/s10669-022-09886-8>
- De Lucia, C., Pazienza, P., & Bartlett, M. (2020). Does good ESG lead to better financial performances by firms? Machine Learning and logistic regression models of public enterprises in Europe. *Sustainability*, 12(13), 5317. <https://doi.org/10.3390/su12135317>
- de Roos, M. (2023). Non-financial firms' Environmental, Social, and Governance (ESG) scores and their financial performance [Tese de mestrado, University of Twente]. University of Twente Student Theses.
- Eccles, R. G., Ioannou, I., & Serafeim, G. (2014). The impact of corporate sustainability on organizational processes and performance (NBER Working Paper No. 17950). National Bureau of Economic Research. <https://www.nber.org/papers/w17950>
- Fahlenbrach, R., Prilmeier, R., & Stulz, R. M. (2018). Why does fast loan growth predict poor performance for banks? *The Review of Financial Studies*, 31(3), 1014–1063. <https://doi.org/10.1093/rfs/hhx109>
- Fatemi, A., Glaum, M., & Kaiser, S. (2018). ESG performance and firm value: The moderating role of disclosure. *Global Finance Journal*, 38, 45–64. <https://doi.org/10.1016/j.gfj.2017.03.001>
- Freeman, R. E. (1984). *Strategic management: A stakeholder approach*. Pitman Publishing.
- Friede, G., Busch, T., & Bassen, A. (2015). ESG and financial performance: Aggregated evidence from more than 2000 empirical studies. *Journal of Sustainable Finance & Investment*, 5(4), 210–233. <https://doi.org/10.1080/20430795.2015.1118917>
- Giese, G., Lee, L.-E., Melas, D., Nagy, Z., & Nishikawa, L. (2019). Foundations of ESG investing: How ESG affects equity valuation, risk, and performance. *The Journal of Portfolio Management*, 45(5), 69–83. <https://doi.org/10.3905/jpm.2019.45.5.069>
- Gillan, S. L., Koch, A., & Starks, L. T. (2021). Firms and social responsibility: A review of ESG and CSR research in corporate finance. *Journal of Corporate Finance*, 66, 101889.

- <https://doi.org/10.1016/j.jcorpfin.2021.101889>
- Hluszko, C., Barros, M. V., de Souza, A. M., Ramos Huarachi, D. A., Castillo Ulloa, M. I., Moretti, V., Puglieri, F. N., & de Francisco, A. C. (2024). Sustainability in practice: Analyzing environmental, social and governance practices in leading Latin American organizations' reports. *Cleaner Production Letters*, 7, 100069. <https://doi.org/10.1016/j.clpl.2024.100069>
- Hussain, M. A., Alsayegh, M. F., & Boshnak, H. A. (2024). The impact of environmental, social, and governance disclosure on the performance of Saudi Arabian companies: Evidence from the top 100 non-financial companies listed on Tadawul. *Sustainability*, 16(17), 7660. <https://doi.org/10.3390/su16177660>
- Jucá, M. N., Muren, P. D., Valentinčič, A., & Ichev, R. (2024). The impact of ESG controversies on the financial performance of firms: An analysis of industry and country clusters. *Borsa Istanbul Review*, 24(6), 1305–1315. <https://doi.org/10.1016/j.bir.2024.08.001>
- Kaminskyi, A., & Nehrey, M. (2023). Fuzzy clustering approach to portfolio management considering ESG criteria: Empirical evidence from the investment strategies of the EURO STOXX Index. *Neuro-Fuzzy Modeling Techniques in Economics*, 12, 40–66. <https://doi.org/10.33111/nfmte.2023.040>
- Kim, S., & Li, Z. F. (2021). Understanding the impact of ESG practices in corporate finance. *Sustainability*, 13(7), 3746. <https://doi.org/10.3390/su13073746>
- Lim, T. (2024). Environmental, social, and governance (ESG) and artificial intelligence in finance: State-of-the-art and research takeaways. *Artificial Intelligence Review*, 57(4), 76. <https://doi.org/10.1007/s10462-024-10708-3>
- Meehan, D., & Corbet, S. (2025). Comparing the resilience of socially responsible and sin investment during the COVID-19 pandemic. *Research in International Business and Finance*, 73, 102537. <https://doi.org/10.1016/j.ribaf.2024.102537>
- Mio, C., Fasan, M., & Scarpa, F. (2023). Materiality investor perspectives on utilities' ESG performance: An empirical analysis of ESG factors and cost of equity. *Utilities Policy*, 82, 101555. <https://doi.org/10.1016/j.jup.2023.101555>
- Nguyen, D. T., Hoang, T. G., & Tran, H. G. (2022). Help or hurt? The impact of ESG on firm performance in S&P 500 non-financial firms. *Australasian Accounting, Business and Finance Journal*, 16(2), 91–102. <https://doi.org/10.14453/aabfj.v16i2.7>
- Orlitzky, M., Schmidt, F. L., & Rynes, S. L. (2003). Corporate social and financial performance: A meta-analysis. *Organization Studies*, 24(3), 403–441. <https://doi.org/10.1177/0170840603024003910>
- Parashar, M., Jaiswal, R., & Sharma, M. (2024). An empirical analysis of ESG and financial performance of clean energy companies through unsupervised Machine Learning. *Procedia Computer Science*, 241, 330–337. <https://doi.org/10.1016/j.procs.2024.08.044>
- Shakil, M. H. (2024). Environmental, social and governance controversies: A bibliometric review and research agenda. *Finance Research Letters*, 70, 106325. <https://doi.org/10.1016/j.frl.2024.106325>
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8, 25. <https://doi.org/10.1186/1471-2105-8-25>
- Vilas, P., Andreu, L., & Sarto, J. L. (2022). Cluster analysis to validate the sustainability label of stock indices: An analysis of the inclusion and exclusion processes in terms of size and ESG ratings. *Journal of Cleaner Production*, 330, 129862. <https://doi.org/10.1016/j.jclepro.2021.129862>
- Vu, T. N., Lehkonen, H., Junttila, J.-P., & Lucey, B. (2025). ESG investment performance and global

- attention to sustainability. *The North American Journal of Economics and Finance*, 75, 102287. <https://doi.org/10.1016/j.najef.2024.102287>
- Wooldridge, J. M. (2020). *Introductory econometrics: A modern approach* (7th ed.). Cengage Learning.
- Zhang, K., & Hao, X. (2024). Corporate social responsibility as the pathway towards sustainability: A state-of-the-art review in Asia economics. *Discover Sustainability*, 5(1), 348. <https://doi.org/10.1007/s43621-024-00577-9>
- Zhou, F., Zhu, J., Qi, Y., Yang, J., & An, Y. (2021). Multi-dimensional corporate social responsibilities and stock price crash risk: Evidence from China. *International Review of Financial Analysis*, 78, 101928. <https://doi.org/10.1016/j.irfa.2021.101928>
- Zhou, G., Liu, L., & Luo, S. (2022). Sustainable development, ESG performance and company market value: Mediating effect of financial performance. *Business Strategy and the Environment*, 31(7), 3371–3387. <https://doi.org/10.1002/bse.3089>

7 Anexos

Anexo A — Nota Técnica: Afinação de Hiperparâmetros do Random Forest

Nota técnica: Os hiperparâmetros dos modelos Random Forest foram selecionados através de GridSearchCV com validação cruzada de 5 folds, de forma a otimizar o desempenho preditivo e mitigar riscos de overfitting.

O espaço de procura considerado incluiu:

$n_estimators \in \{300, 500\}$;

$max_depth \in \{None, 15\}$;

$min_samples_leaf \in \{3, 7\}$.

Os melhores parâmetros para cada modelo encontram-se reportados na coluna “Best_params” do ficheiro de resultados (não incluído na tabela principal por questões de síntese).

De forma geral, os modelos apresentaram como configurações ótimas valores de $max_depth=None$, $min_samples_leaf=3$ e $n_estimators$ entre 300 e 500, indicando preferência por árvores relativamente profundas com regularização moderada.

Anexo	B–Detalhes Implementação	Técnicos	da
-------	-----------------------------	----------	----

A análise empírica foi conduzida em Python 3.11 (Google Colab), com recurso às seguintes bibliotecas:

- pandas para manipulação de dados;
- numpy para operações numéricas;
- linearmodels (versão 7.0) para modelos de painel;
- statsmodels para diagnósticos econométricos;
- scikit-learn para Random Forest, GridSearchCV e permutation importance;

- `scipy.stats` para testes de hipóteses adicionais.

Os hiperparâmetros do Random Forest foram seleccionados via GridSearchCV com 5-fold cross-validation, sobre o conjunto de treino. O espaço de hiperparâmetros explorado foi: `n_estimators` $\in$ {300, 500}; `max_depth` $\in$ {None, 15}; `min_samples_leaf` $\in$ {3, 7}. A semente utilizada foi `random_state=42` em todas as estimações que envolvam estocasticidade, garantindo reprodutibilidade.